Ejercicio 1

Mencione y explique brevemente cuales son las principales violaciones de los supuestos de un modelo lineal clásico como se pueden detectar en la práctica.

Considerando el modelo lineal clásico:

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon \quad \text{con} \quad E(\varepsilon) = \mathbf{0}, \quad Var(\varepsilon) = \sigma^2\mathbf{I} \quad \text{y} \quad \varepsilon \sim N(\mathbf{0}, \sigma^2\mathbf{I})$$

Las principales violaciones a los supuestos son:

1. **No linealidad.**

El modelo supone que la relación entre la variable respuesta y los predictores puede representarse mediante una combinación lineal de los parámetros. Así una de las violaciones ocurre cuando existe una relación funcional curva que el modelo no captura. La evidencia de esta violación se exhibe principalmente en un patrón visual en los residuales.

Formas de Detección:

- Gráfico de residuos vs valores ajustados.
- Gráfico de variable de respuesta vs cada uno de los predictores

En ambos casos si hay algún patrón no lineal o aleatorio hay evidencia de No Linealidad.

2. **Heterocedasticidad**

El supuesto establece que $Var(\varepsilon) = \sigma^2$ para todas las observaciones, es decir, la varianza es constante, sin embargo, muchos de los casos ocurre que $Var(\varepsilon_i) \neq \sigma^2$, esta es uno de los supuestos que comúnmente se pasan por alto.

Formas de Detección:

- Gráfico de residuos vs valores ajustados, en caso de observar algún patrón de crecimiento o decrecimiento de la varianza hay que investigar más a fondo o proceder con pruebas de hipótesis.
- Pruebas de hipótesis: Breush-Pagan, White, Spearman y Goldfed Quandt.

3. **Autocorrelación o Falta de Independencia**

Se supone que los errores son no correlacionados $Cov(\varepsilon_i, \varepsilon_j) = 0$ para $i \neq j$. Esto cuando se trabaja con datos reales los errores $\varepsilon_1, \varepsilon_2, \cdots, \varepsilon_n$ presentan una relación consecutiva, por lo que es natural revisar si hay presencia de autocorrelación, es decir: $Cov(\varepsilon_i, \varepsilon_{i-1}) \neq 0$.

Sin embargo otras herramientas permiten probar correlación en la variable dependiente, general o funcional.

Formas de Detección:

- Pruebas de hipótesis: Durbin-Watson, h de Durbin y Prueba de rachas.

4. **No normalidad de los residuos**

Aunque el modelo y la estimación por mínimos cuadrados no exige la normalidad, para el cálculo de pruebas de hipótesis e intervalos de confianza es indispensable sobre todo en muestras pequeñas el supuesto: $\varepsilon_i \sim N(0, \sigma^2)$

Formas de Detección:

- Histograma de residuos.
- Q-Q Plot y P-P Plot.
- Pruebas de bondad de ajuste: Shapiro-Wilk o Jarque-Bera

4. **Multicolinealidad**

Este supuesto es particular de la regresión múltiple. Sucede cuando 2 o más variables explicativas presentan una relación lineal fuerte. Esto dificulta separar el efecto lineal de cada predictor y una consecuencia es que aunque los estimadores no dejan de insesgados, sus varianza aumentan considerablemente.

Formas de Detección:

- Coeficiente de correlación simples y parciales.
- R^2 muy elevada y coeficientes no significativos.
- Índice de tolerancia y Factor de incremento de la varianza.
- Número de condición (con la matriz diseño normalizada).

Ejercicio 2

Con la siguiente información brindada en el ejercicio, se completa la tabla que queda de la siguiente forma:

Estadístico	Valor
Coeficiente de correlación múltiple	0.9852
R2	0.9707
R2 ajustado	0.9648
Error típico de la estimación	2.5850
Observaciones	19

Fuente	gl	SC	MC	F	p-valor
Regresión	3	3316.6484	1105.5495	165.4405	1.025e-11
Residuos	15	100.2369	6.6825	nan	nan
Total	18	3416.8853	nan	nan	nan

Variable	Coeficiente	Error Típico	Estadístico t	Probabilidad	Inferior 95%	Superior 95%
Intercepto	5.6484	2.9547	1.9117	0.07522	-0.6494	11.9462
X	3.5785	1.5659	2.2853	0.03727	0.2409	6.9161
X2	0.6536	0.2313	2.8258	0.01278	0.1606	1.1466
X3	-0.0552	0.0098	-5.6327	4.767e-05	-0.0761	-0.0343

Considerando estos estadísticos:

- El modelo presenta alto grado de ajuste, con $R^2 = 0.9707$ es decir el 97.07% de la varianza de la variable respuesta es explicada por $X, X2, X3$.

- La prueba F asociada a la tabla ANOVA es favorable, por lo que el modelo es estadísticamente significativo en conjunto.
- Los coeficientes de $X, X2, X3$ son estadísticamente significativos, es decir cada variable en presencia de las restantes aporta información al modelo.
- El intercepto no resulta significativo, por lo que no se rechaza que sea igual a cero.

Ejercicio 3

En un laboratorio se generan reacciones químicas a partir de un material base. Se dispone del dataset reaccionesQuimicas.csv con las siguientes variables:

- Y: Cantidad de producto final obtenido.
- X_1: Temperatura (grados Celcius).
- X_2: Concentración de material base (%).
- X_3: Tiempo de reacción (horas).

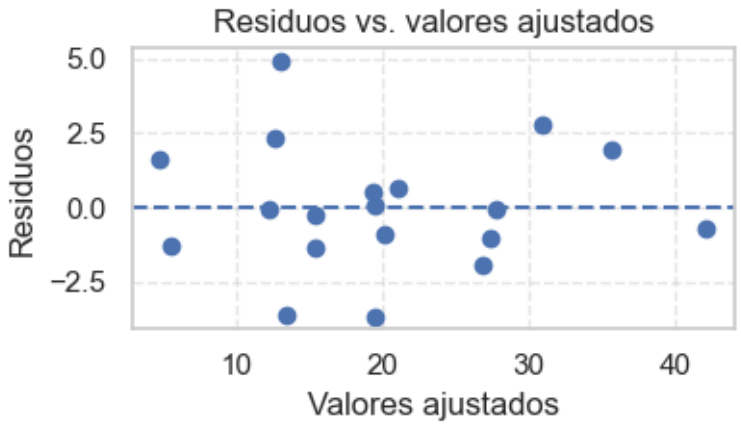
En base a la información se ajusto el modelo:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3$$

Del cuál se obtuvo el siguiente ajuste:

Variable	Coeficiente	Error estándar	t	p-valor	[0.025	0.975]
const	332.1110	18.6929	17.7667	1.74e-11	292.2679	371.9540
x1	-1.5460	0.0990	-15.6103	1.10e-10	-1.7570	-1.3349
x2	-1.4246	0.1476	-9.6482	7.99e-08	-1.7393	-1.1099
x3	-2.2374	0.3398	-6.5839	8.67e-06	-2.9617	-1.5130

Donde podemos observar que los coeficientes son significativos al tener p-values menores al nivel de significancia (0.05), un elemento a notar es que el error estándar del intercepto es grande, tal vez por alguna presencia de multicolinealidad con el. A través de los valores ajustados y residuos se obtuvo un $R^2 = 95.51\%$, dichos valores se muestran a continuación:



Gráficamente, los residuos no presentan patrones o curvaturas aparentes y se distribuyen alrededor de cero con una dispersión aproximadamente constante. Esto proporciona evidencia gráfica a favor de los supuestos de linealidad y homocedasticidad. Sin embargo, la gráfica no permite evaluar por sí sola los supuestos por lo que haremos pruebas de hipótesis. Además, la tabla ANOVA del modelo propuesto nos arroja.

Fuente	gl	SC	CM	F	p-valor
Regresión	3	1707.1580	569.0527	106.4664	2.459e-10
Error	15	80.1735	5.3449	nan	nan
Total	18	1787.3316	nan	nan	nan

El estadístico F es 106.4664, con $gl_1 = 3$ y $gl_2 = 15$, y un $p-value$ de $2.459e-10$. Se rechaza la hipótesis de que los coeficientes asociados a las variables predictoras son cero al 5%, por lo que existe evidencia estadística de que el conjunto de variables explicativas aporta información para explicar Y. Ahora veamos un diagnóstico general para este modelo.

Diagnóstico	Resultado	p-valor
Residuos atípicos (|residuo est. sin leverage| > 2)	12	—
Leverage (> 2p/n)	1	—
Distancia de Cook (> 4/(n-p))	Ninguna	—
Shapiro-Wilk	0.9693	0.7621
Jarque-Bera	0.3672	0.8323
Breusch-Pagan	3.7334	0.2917
White	7.5016	0.5850
Durbin-Watson	1.4763	—
Breusch-Godfrey (1 rezago)	1.3021	0.2538
Prueba de rachas	-0.8550	0.3925
VIF máximo	1242.1345	—
Número de condición	5982.2021	—

En términos generales, las pruebas realizadas no proporcionan evidencia estadísticamente significativa de incumplimiento de los supuestos de normalidad (Shapiro-Wilk, Jarque-Bera), homocedasticidad (Breush-Pagan, White), independencia (Durbin-Watson, Breush-Godfrey) y aleatoriedad de los residuos (Prueba de rachas). Se identifica la observación 12 como potencialmente atípica por presentar un residuo estandarizado superior a 2 en valor absoluto, mientras que la observación 1 presenta un leverage superior al umbral establecido. Sin embargo, ninguna observación supera el criterio utilizado para la distancia de Cook. Por otro lado, los valores elevados del VIF máximo (1242.1345) y del número de condición (5982.2021) evidencian una fuerte presencia de multicolinealidad entre las variables explicativas (que podría explicar el error típico elevado del intercepto), por lo que este aspecto requiere especial atención en el modelo.

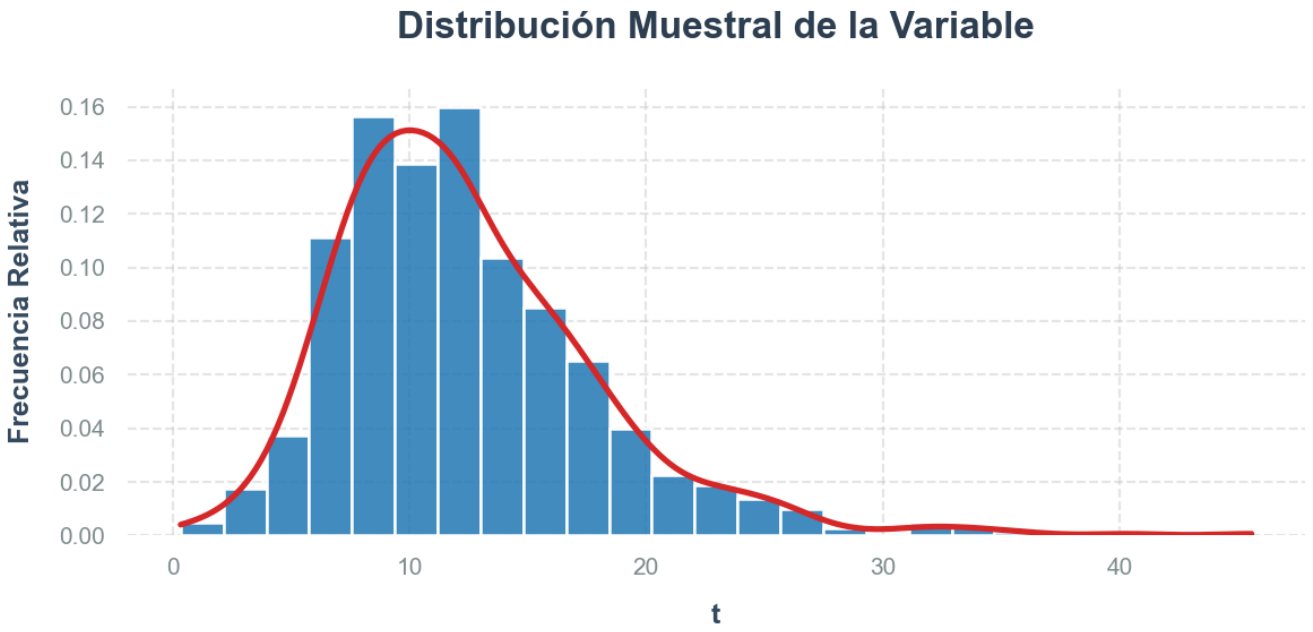
NOTA: Debido a este último resultado decidí profundizar en el cálculo del VIF y del número de condición. Un modelo alternativo se encuentra en el documento de classroom.

Ejercicio 4

Utilizando los datos del dataset valoresExtremos.csv, los cuales provienen de una distribución Gumbel que tiene como función de densidad:

$$f(t;\mu,\lambda) = \frac{1}{\lambda} exp\left(-\frac{t-\mu}{\lambda}\right) exp\left(-exp\left(-\frac{t-\mu}{\lambda}\right)\right), \quad t \in \mathbb{R}$$

Es de nuestro interés estimar los parámetros μ y λ con la muestra obtenida, para ello hay que linealizar el modelo para representarlo como una regresión lineal múltiple, los detalles de la función de supervivencia y la linealización se encuentran en el archivo de Classroom. Veamos un histograma de dichos datos.



Así podemos observar una distribución leptocúrtica, con sesgo positivo. Parece tener una media al rededor del 10, por lo que tal vez alguno de los parámetros este relacionado con este valor. La función de supervivencia teórica:

$$S(t;\mu,\lambda) = 1 - exp\left(-exp\left(-\frac{t-\mu}{\lambda}\right)\right),$$

Linealización:

$$ln\left(-ln\left(1 - S(t;\mu,\lambda)\right)\right) = \frac{\mu}{\lambda} - \frac{t}{\lambda} = \beta_0 + \beta_1 t$$

Y por lo tanto, una vez que el modelo sea ajustado, los parámetros serán estimados por:

$$\mu = -\frac{\beta_0}{\beta_1}, \quad \lambda = -\frac{1}{\beta_1}$$

Donde al tener únicamente una muestra, estimamos la supervivencia de la siguiente manera:

$$\hat{S}_1(t) = \frac{(\text{cantidad de valores} > t) + \frac{1}{2}}{n} = \hat{S}_C(t) + \frac{1}{2n}$$

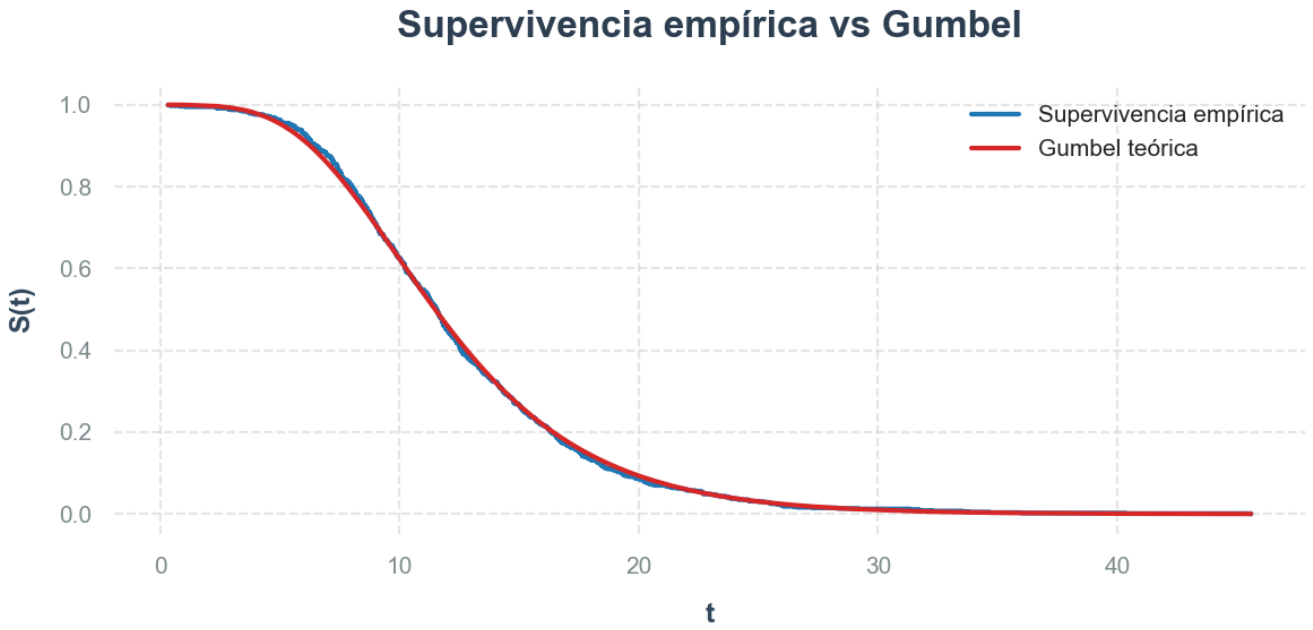
No es la función de supervivencia clásica (aunque esta relacionada), sumamos $1/(2n)$ debido que en la versión clásica habría un problema con el último dato ya que al hacer la transformación se tendría $ln(-ln(1-\frac{0}{n})) = ln(-ln(1)) = ln(0)$ lo cual no esta definido, así aseguramos que este entre 0 y 1 sin eliminar observaciones. Así aplicando el modelo propuesto, los coeficientes y R^2 son:

Estadístico	Valor	p-value (t)
R2	0.996548	-
beta_0	2.272481	0.000000
beta_1	-0.229699	0.000000

Tenemos un R^2 muy alto el 99.65% de la variabilidad es explicada por los datos de la muestra, en parte así lo construimos a través de la linealización, los coeficientes son significativos, con el valor de estos últimos nos quedan las siguientes estimaciones de μ y λ

Parámetro	Valor
mu	9.893283
lambda	4.353516

Obtenidos estos parámetros es posible calcular la función de supervivencia teórica y compararla con la empírica clásica (a la empírica $S_1(t)$ le restaremos $1/(2n)$).



Así el modelo propuesto, la estimación de los parámetros y la gráfica de comparación de funciones de supervivencia que presenta casi una superposición exacta, nos indica un buen ajuste, por lo que se podría utilizar la distribución con parámetros estimados para realizar conclusiones sobre el fenómeno estudiado.

Ejercicio 5

Habíamos definido el vector de errores $e = Y - \hat{Y}$. Demuestre que los residuos son ortogonales al vector de predicciones, es decir:

$$\hat{Y}'e = 0$$

Demostración. Recordemos que en el modelo lineal al resolverlo por mínimos cuadrados se llega a la siguiente ecuación normal:

$$X'X\hat{\beta} = X'Y$$

Que en este caso suponiendo que el modelo tiene solución se tiene que $X'X$ es invertible, así se llega a la solución de los coeficientes:

$$\hat{\beta} = (X'X)^{-1}X'Y$$

Los valores ajustados son $\hat{Y} = X\hat{\beta}$ y los residuos $e = Y - \hat{Y}$. Retomando la ecuación normal:

$$X'X\hat{\beta} = X'Y \Longrightarrow X'Y - X'X\hat{\beta} = 0 \Longrightarrow X'(Y - X\hat{\beta}) = 0 \Longrightarrow X'(Y - \hat{Y}) = 0 \Longrightarrow X'e = o$$

Es decir los residuos son ortogonales a cada fila de X', además recordando que $(AB)' = B'A'$ se llega a:

$$\hat{Y}'e = (X\hat{\beta})'e = \hat{\beta}'X'e = 0 \text{ esto ya que } X'e = 0$$

$$\therefore \hat{Y}'e = 0$$

■

Ejercicio 6

Considerando el siguiente modelo de regresión lineal múltiple sin intercepto:

$$Y = \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3$$

Donde la tercer variable es multicolineal de la siguiente manera: $X_3 = 2X_1 + X_2$ demuestre que:

a) $X'X$ no es invertible

Demostración. (Contradicción) Procedemos a través del Álgebra Lineal. Observando que el modelo puede escribirse de la forma $Y = X\beta + \varepsilon$ con $X = (X_1, X_2, X_3)$ vectores columna y se cumple que $X_3 = 2X_1 + X_2 \Longrightarrow 2X_1 + X_2 - X_3 = 0$, es decir, una combinación lineal de las columnas, esto implica que existe un vector no nulo $\vec{c}$ tal que $X\vec{c} = 0$. Este vector es:

$$\vec{c} = \begin{pmatrix} 2 \\ 1 \\ -1 \end{pmatrix} \neq \vec{0} \Longrightarrow X\vec{c} = (X_1, X_2, X_3)\begin{pmatrix} 2 \\ 1 \\ -1 \end{pmatrix} = 2X_1 + X_2 - X_3 = \vec{0}$$

Esto implica que $Ker(X) \neq \{\vec{0}\}$ y por lo tanto X no tiene rango columna completo. Ahora supongamos por contradicción que $X'X$ es invertible, entonces $Ker(X'X) = \{\vec{0}\}$, pero considerando el vector $\vec{c} \neq \vec{0}$ anterior:

$$(X'X)\vec{c} = X'(X\vec{c}) = X'(\vec{0}) = \vec{0} \quad \text{ya que} \quad X'\vec{c} = \vec{0}$$

Entonces $\vec{c} \in Ker(X'X)$ lo cual es una contradicción de suponer que $Ker(X'X) = \{\vec{0}\}$, por lo tanto debe ser que $Ker(X'X) \neq \{\vec{0}\}$

$$\therefore X'X \text{ no es invertible}$$

■

b) $X'X$ tiene un valor propio igual a 0.

Demostración. Utilizando el vector $\vec{c}$ de la demostración anterior y que $(X'X)\vec{c} = 0$, además recordando que λ es un valor propio de una matriz A si existe un vector no nulo $\vec{v}$ tal que $A\vec{v} = \lambda\vec{v}$, se tiene:

$$\vec{c} = \begin{pmatrix} 2 \\ 1 \\ -1 \end{pmatrix} \neq \vec{0} \Longrightarrow (X'X)\vec{c} = \vec{0} = 0\vec{c}$$

$$\therefore \lambda = 0 \text{ es un valor propio de } X'X$$

■

Ejercicio 7

El comportamiento de los datos dentro del conjunto de datos dataset1.csv inmediatamente destaca una relación polinómica, al tener 2 puntos de inflexión parece demasiado a la gráfica de un polinomio de grado 3, es decir $f(x) = a + bx + cx^2 + dx^3$, por ello es el modelo propuesto para describir la tendencia de la nube de puntos es:

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3$$

En el cuál se obtuvieron los siguientes coeficientes y significancia.

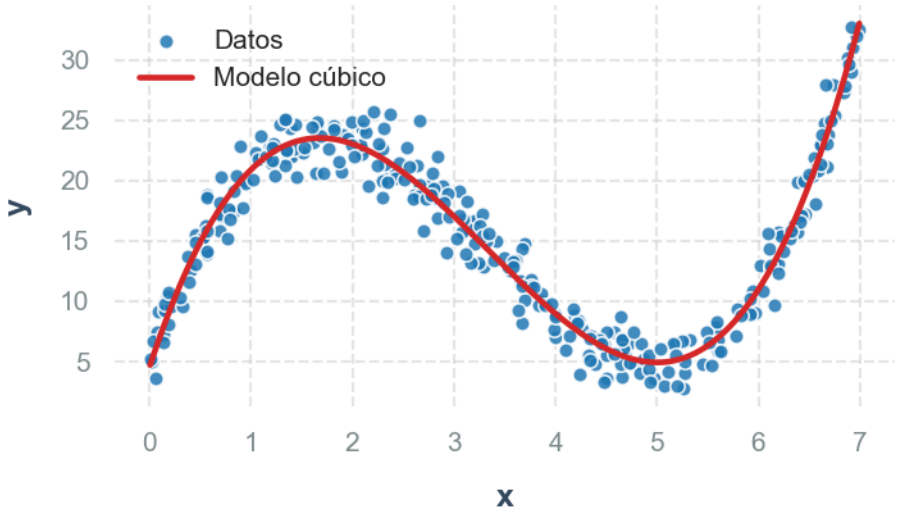
Variable	Coeficiente	Error estándar	t	p-valor	[0.025	0.975]
const	4.5594	0.3408	13.3798	2.97e-32	3.8887	5.2300
x1	25.4713	0.4291	59.3610	1.97e-166	24.6268	26.3157
x2	-10.1413	0.1449	-69.9828	3.47e-186	-10.4265	-9.8561
x3	1.0124	0.0137	74.0248	5.14e-193	0.9855	1.0393

Donde podemos observar que tenemos errores estándar pequeños en comparación a los coeficientes, los p-value de todos los coeficientes son muy pequeños, lo que implica que en su forma individual son significativos a un nivel de significancia del 0.05. Veamos que el modelo es significativo a través de la tabla ANOVA.

Fuente	gl	SC	CM	F	p-valor
Regresión	3	14437.5496	4812.5165	1994.1063	6.290e-196
Error	296	714.3576	2.4134	nan	nan
Total	299	15151.9072	nan	nan	nan

Cuyo p-value es menor a 0.05, por lo que el modelo es estadísticamente significativo, al menos una de las potencias de la variable x esta aportando información relevante al modelo. Adicionalmente se tiene un coeficiente de determinación $R^2 = 0.952853$, es decir el 95.28% de la variabilidad en Y es explicada por los predictores involucrados. Así considerando los coeficientes, el modelo ajustado y gráfica de ajuste son:

$$Y = 4.5594 + 25.4713X - 10.1413X^2 + 1.0124X^3$$



Ejercicio 8

Con los datos dados en el ejercicio hagamos la comparación entre los dos modelos presentados a continuación. Considerando las siguientes variables:

- Y: Precio estimado en Miles de dólares.
- X_1: Área construida (en m^2).
- X_2: Habitaciones.
- X_3: Garaje (1 si tiene 0 si no).

Modelo 1: $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2$
Modelo 2: $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3$

Para el primer modelo se obtiene un $R^2 = 0.945$ y un $R^2_{ajust} = 0.942$, mientras que para el segundo se obtiene un $R^2 = 0.976$ t y un $R^2_{ajust} = 0.974$, es decir el segundo modelo presenta una mejor explicación de la variabilidad de la variable objetivo, ambos modelos tienen coeficientes significativos en conjunto con valores F asociados a la tabla ANOVA de 303.1 y 454.7 respectivamente. Además, el modelo que no considera la variable Garaje obtuvo un error típico de 35.7745 mientras que el que si la considera tuvo un error típico de 24.2272. Los coeficientes y valores de significancia del primer modelo son:

Variable	Coeficiente	Error estándar	t	p-valor	[0.025	0.975]
const	11.8888	17.3505	0.6852	0.4977	-23.3347	47.1122
Area(m2)	0.7194	0.2224	3.2351	0.0027	0.2679	1.1708
Habitaciones	24.5625	9.2104	2.6668	0.0115	5.8644	43.2606

Observemos que los coeficientes relacionados a las variables explicativas de este modelo son significativos, mientras que el de el intercepto no, su error estándar es grande tal vez se deba a presencia de multicolinealidad no esencial, algo similar ocurrido en el modelo profundizado del ejercicio 3. Para el modelo que si considera si la casa tiene o no garaje:

Variable	Coeficiente	Error estándar	t	p-valor	[0.025	0.975]
const	-23.8828	12.9733	-1.8409	0.0744	-50.2477	2.4820
Area(m2)	0.9739	0.1556	6.2594	0.0000	0.6577	1.2901
Habitaciones	14.6199	6.4220	2.2765	0.0292	1.5688	27.6710
Garaje(dummy)	52.8529	8.1250	6.5050	0.0000	36.3409	69.3649

En este caso los coeficientes de las variables predictoras siguen siendo significativos, el error típico de los mismos bajo y el intercepto (relacionado a la categoría de referencia: no tiene garaje) sigue siendo no significativo al nivel 0.05 pero su error estándar se redujo, una estadística adicional obtenida de ambos modelos es el BIC (castiga más a modelos más complejos), donde el primer modelo obtuvo 387.5 y el segundo 360.4. Así podemos concluir que el segundo modelo que incorpora la variable garaje es un modelo más completo, incrementando el R^2 y el R^2_{ajust}, disminuyendo el error típico de la regresión y de los coeficientes y resultando en un menor BIC.