

UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

FACULTAD DE CIENCIAS



SEMINARIO DE ESTADÍSTICA I

TAREA 1:
MODELOS LINEALES GENERALIZADOS

Profesor: Gonzalo Pérez de la Cruz
Ayudante: César Humberto Valle Márquez
Grupo: 9275

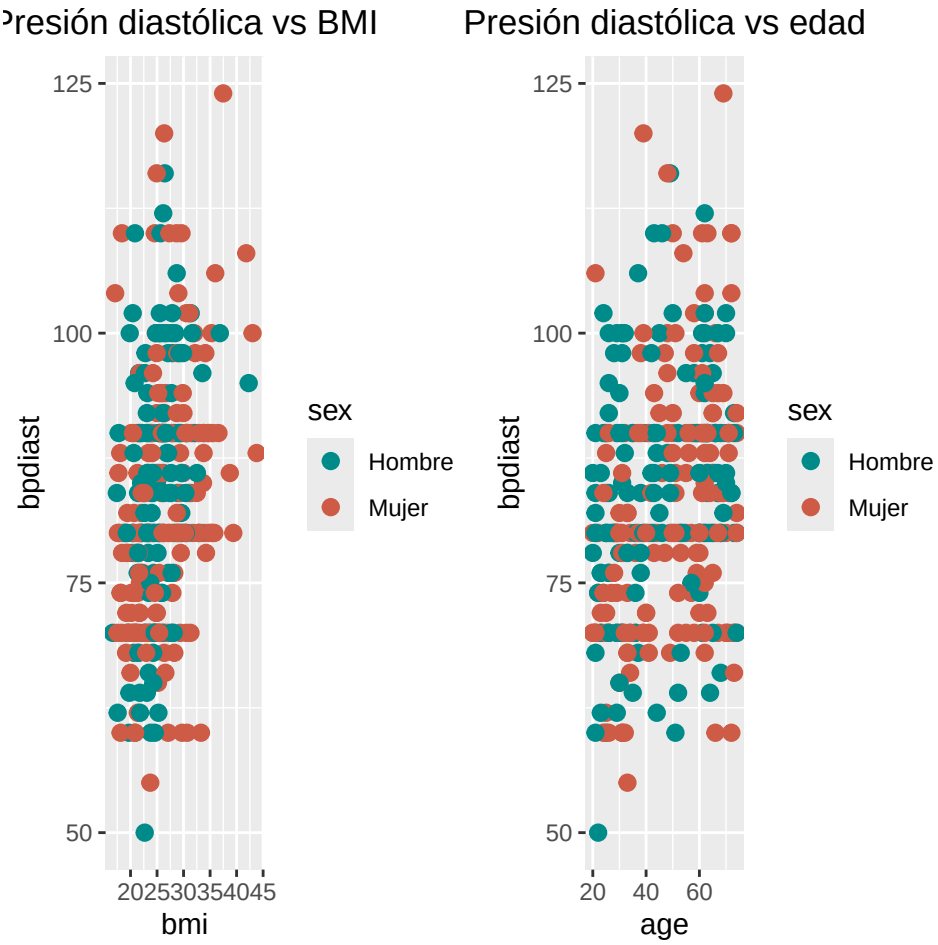
Alumno:

- Alvarado Eriza Yael Jesús
- Castro Telles Omar Tadeo
- Méndez García Efrén
- Romero Medina Emiliano
- Santos Zavala Javier Eduardo

Ejercicio 1. Regresión lineal múltiple

La base de datos Preg1A.csv contiene información sobre 350 pacientes seleccionados de forma aleatoria. Se desea analizar si existe una asociación entre la presión arterial diastólica (bpdiast) y el índice de masa corporal (bmi), en particular, si es posible observar que tener un índice de masa corporal alto se asocia con una alta presión arterial diastólica. Para realizar este análisis se indica que se considere el sexo (sex: 1-hombre, 2-mujer) y la edad (age) de los pacientes, pues la presión arterial diastólica podría variar de acuerdo con estos factores.

Para realizar un primer análisis visiual de los datos, tenemos las siguintes gráficas:



En la primera de ellas se observa una tendencia ligeramente ascendente, es decir, conforme aumenta el índice de masa corporal (BMI), también tiende a aumentar la presión arterial diastólica. Además, tanto en hombres como en mujeres se aprecia el mismo patrón, aunque el nivel de presión parece similar entre sexos. Con la segunda gráfica no se aprecia una relación clara entre la edad y la presión diastólica: los puntos están más dispersos y sin una tendencia definida. Aunque puede haber una leve inclinación ascendente (mayor edad, ligeramente mayor presión), la variabilidad es alta y no hay evidencia visual fuerte de linealidad.

Por lo anterior decidimos ajustar un modelo de regresión lineal múltiple sin interacciones entre las covariables, es decir: $\mathbb{E}[\mu_i] = \beta_0 + \text{bmi}\beta_1 + \text{age}\beta_2 + \text{sex}_2\beta_3$.

Al ajustarlo se obtuvieron p-values que indican que todas las β aportan información significativa al modelo de regresión. Ahora, para verificar que efectivamente el modelo es el adecuado debemos revisar sus supuestos (linealidad, homocedasticidad y normalidad), donde se tiene:

- Linealidad

Realizando un test de no linealidad se obtuvieron p-values que nos indicaron que el modelo cumple la linealidad para las variables bmi y sex (por ser categoría). Sin embargo, la variable age podría tener una relación no lineal con la presión arterial sistólica, ya que presenta un p-value de 0.025, menor a 0.05, lo que a primera instancia nos indica que sería útil realizar una transformación.

- Homocedasticidad

Para verificar la homocedasticidad se realizó la prueba de varianza constante, donde se obtuvierón p-values mayores a 0.05, lo cual indica que no hay evidencia estadisticamente suficiente en contra del supuesto de homocedasticidad del modelo, por lo que no rechazamos que cuenta con varianza constante.

- Normalidad

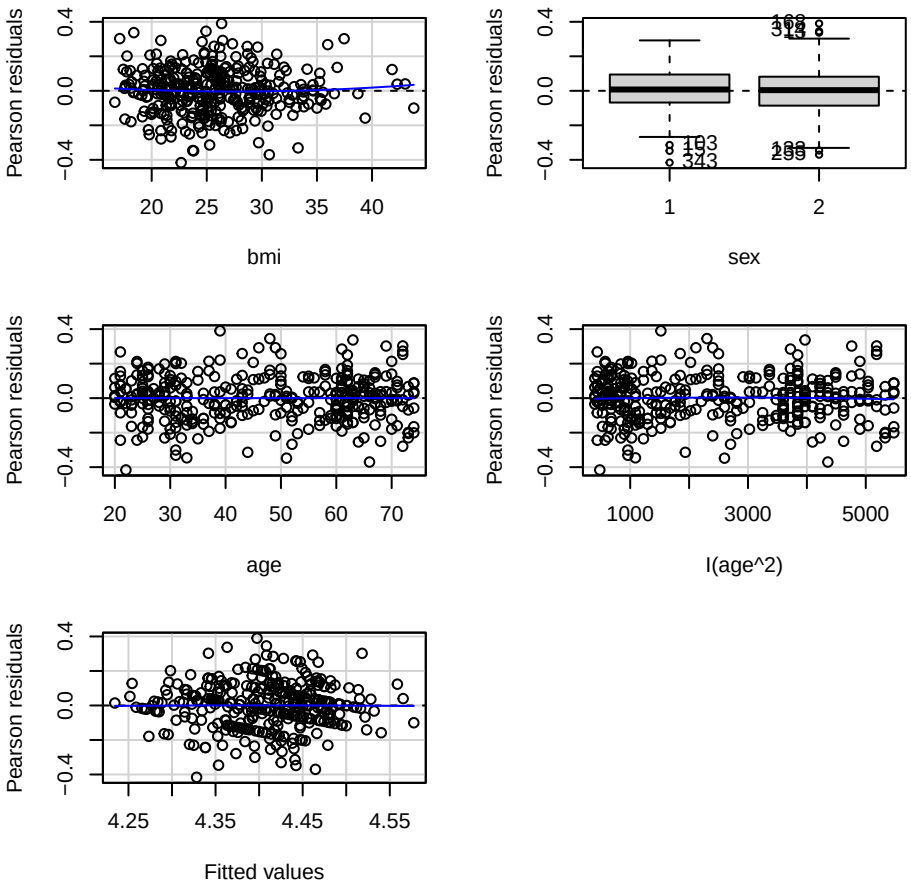
Finalmente, para verificar la normalidad se realizaron las pruebas de Shapiro-Wilk y Lilliefors, donde los p-values obtenidos de estas pruebas fueron menores a 0.01, lo que muestra evidencia significativa en contra del supuesto de normalidad. Por lo anterior, no podemos concluir que este modelo es el más ótimo, ya que no cumple el supuesto de normalidad ni la linealidad para la variable age.

Entonces, dado que el modelo resulta no ser el más adecuado, para Corregir la no normalidad decidimos realizar una transformación del tipo Box-Cox con $\lambda = 0$, es decir, aplicamos logaritmo al valor esperado de la variable respuesta bpdiast. Además, a la variable age se le fijó una transformación polinómica, ya que la relación entre age y la presión arterial es significativamente no lineal. De esta manera, el modelo resultante es:

$$\ln \mu_i = \beta_0 + \text{bmi}\beta_1 + \text{sex}_2\beta_2 + \text{age}\beta_3 + \text{age}^2\beta_4$$

Para verificar su eficiencia se revisaron nuevamente los supuestos.

- Linealidad




```
##            Test stat Pr(>|Test stat|)
```

```
## bmi           0.7588          0.4485
## sex
## age           0.5169          0.6055
## I(age^2)     -1.1462          0.2525
## Tukey test   -0.0893          0.9288
```

De dichas gráficas se pudo interpretar lo siguiente:

- Residuos vs. BMI. Los puntos están dispersos aleatoriamente alrededor de 0, sin una forma definida y la línea de ajuste azul es casi horizontal, lo que indica que sí hay linealidad.
- Residuos vs. Sexo. Para ambos grupos se aprecia que las medianas están muy cerca de 0 y las dispersiones son similares. Y aunque hay outliers, no hay evidencia de problemas de ajuste por sexo.
- Residuos vs. age y Residuos vs. I(age^2). Es posible notar que no hay ninguna curvatura en ambos casos, más bien parece ser una línea recta, además de que la nube de puntos está centrada en 0, por lo que la relación con la edad está bien modelada.
- Residuos vs. valores ajustados. Nuevamente los residuos oscilan de manera homogénea alrededor de 0 en todo el rango de valores ajustados y no hay patrones evidentes, lo que podría indicar linealidad y homocedasticidad.

Por su parte, los p-value de bmi, age y I(age^2) nos indican que ahora ya no hay evidencia en contra de la linealidad. Y el p-value del Tukey test que resulta ser de 0.9288 nos confirma que el modelo final cumple con la suposición de linealidad en conjunto.

- Homocedasticidad

Aplicando la prueba de varianza constante al nuevo modelo, esto arrojó un p-value de 0.553 lo cual nos indica que no existe evidencia significativa en contra del supuesto de varianza constante, por lo que el modelo transformado sigue cumpliendo el supuesto de homocedasticidad.

- Normalidad

Finalmente, realizando las pruebas de Shapiro-Wilk y Lilliefors para verificar los supuestos de normalidad, los p-values obtenidos de estas pruebas fueron mayores a 0.05, por lo que no hay evidencia significativa en contra del supuesto de normalidad. Con ello, este nuevo modelo transformado nos indica que no hay evidencia estadisticamente en contra de los supuestos de linealidad, homocedasticidad y normalidad, así que podemos aceptarlo.

Ahora bien, ante la posible pregunta de ¿se puede indicar que para una persona de cierta edad y sexo, tener un índice de masa corporal alto se asocia con una alta presión arterial diastólica? Podemos decir que sí es posible.

Para ello, si consideramos personas del mismo sexo y edad, pero con distinto índice de masa coporal (bmi), queremos identificar si aquellos con bmi alto tendrán la presión arterial diastólica más alta que aquellos con bmi bajo. Entonces, dado que el logaritmo es una función creciente, nos basta con verificar si la variable β_1 asociada a bmi también es positiva, es decir, es mayor a 0, ya que si no fuera el caso, mayor índice coroporal implicaría menor presión arterial. Por lo tanto, realizamos la siguiente prueba de hipótesis:

$$H_0 : \beta_1 = 0 \; vs \; H_a : \beta_1 > 0$$

Realizando esa prueba se obtiene un p-value demasiado pequeño de 1.31e-08, lo que nos hace rechazar la hipótesis nula y con ello aceptar que $\beta_1 > 0$, por lo que sí, mayor índice corporal implica mayor presión arterial diastólica.

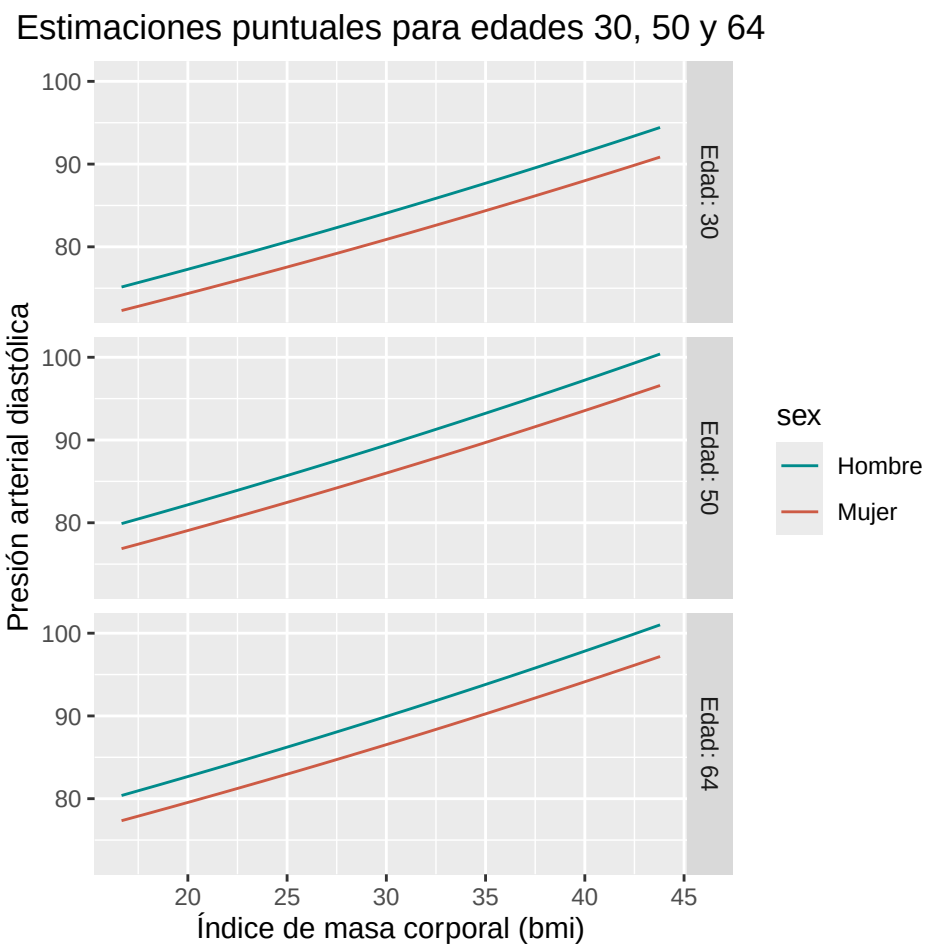
Además, obtuvimos que $\beta_1 = 0.008417$, lo que nos indica que considerando una edad y sexo específicos, por cada unidad de incremento en el índice de masa corporal, se prevé un aumento del 0.84% en la presión arterial diastólica.

Asimismo, nos planteamos si el sexo también influye en la presión arterial diastólico, es decir que ante un índice de masa corporal y edad específica, ser mujer (sexo 2) está asociado con una presión arterial diastólica más baja, por lo que se realizó la siguiente prueba de hiótesis:

$$H_0 : \beta_2 = 0 \; vs \; H_a : \beta_2 < 0$$

Al ejecutarla se obtuvo un p-value de 0.00348, menor a 0.05, así que se rechaza la hipótesis nula y aceptamos que $\beta_2 < 0$, por lo que sí existe una diferencia entre la presión arterial diastólica entre hombres y mujeres, pues pertencer al grupo 2 (mujeres) implica tener una disminuación de aproximadamente el 3.78% de presión arterial diastólica respecto a los hombres

Por último, realizando un gráfico con las estimaciones puntuales de neustro modelo asociadas a la relación entre bpdiast y bmi entre las edades 30, 45 y 65, se obtuvo lo siguiente:



En la gráfica podemos apreciar lo obtenido anteriormente, es decir, que un mayor índice de masa corporal (bmi) está asociado a tener una mayor presión arterial diastólica, ya que se observa la tendencia creciente en las tres gráficas conforme aumenta el bmi. Por su parte, también se aprecia que efectivamente las mujeres presentan una presión arterial diastólica menor a la de los hombres durante todas las edades, aunque presentan la misma tendencia creciente. Finalmente, comparando las 3 gráficas se puede decir que en la edad de 30, los niveles esperados de presión arterial diastólica son menores a los de edad 50 y 64, sin embargo, entre estas dos edades no parece haber gran diferencia. Esto resulta ser consecuencia de que la variable age no cumplía con la linealidad.

Ejercicio 2

Resumen ejecutivo

Este reporte presenta un análisis de la relación entre el índice de masa corporal y la presión arterial diastólica, tomando en cuenta la edad y el sexo de los 350 pacientes seleccionados; el principal objetivo es probar si tener un mayor índice de masa corporal implica tambien tener una alta presión arterial diastólica, para eso buscaremos un modelo lineal generalizado que evalue la asociación de las variables de manera optima.

Selección del modelo

Con el propósito de obtener un modelo adecuado que modele E(bpdiast; bmi,sex, age) y analice si hay una realcion entre la presión arterial diastólica (bpdiast) y el índice de masa corporal (bmi), considerando el sexo (sex) y la edad (age); se llevó a cabo una exploración de modelos lineales generalizados mediante una malla que prueba simultaneamente las distribuciones normal, gamma e inversa gaussiana, junto con sus funciones liga como la identidad, logarítmica, inversa e inversa cuadrada.

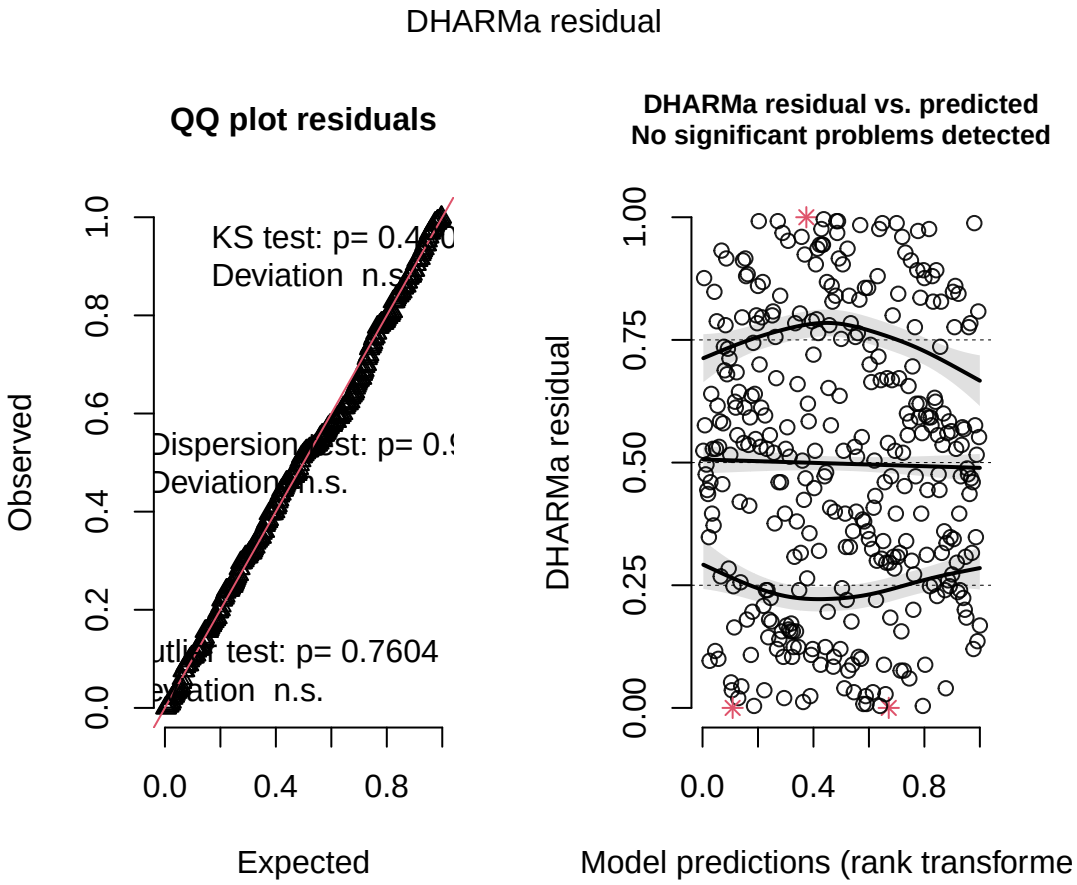
Tambien se tomaron en cuenta varias transformaciones aplicables a las covariables bmi y age como la polimonial, potencia y logarítmica; para observar si alguna de ellas mejoraba el ajuste del modelo.

Para elegir el modelo más apropiado buscamos el que tenga el valor mas bajo de AIC que nos dio como resultado un modelo con función de distribución Gamma, la función liga de identidad, bmi elevada al cuadrado y age con un termino lineal y otro cuadratico.

$$\mathbb{E}(\mu_i) = \beta_0 + \text{bmi}^2\beta_1 + \text{age}\beta_2 + \text{age}^2\beta_3 + \text{sex}_2\beta_4$$

El valor del AIC del modelo seleccionado es de 2667.479.

Ahora, veamos la comprobación de los supuestos del modelo con Dharma.



En la grafica de la izquierda (QQPlot) vemos que se ajustan bastante bien los residuales, ademas ambas pruebas (Dispersion y KS test) tienen un p-value mayor a 0.05. Por otro lado, vemos que aunque esten un poco onduladas algunas de las lineas en

negro (0.25 y 0.75), no se encuentra ningun problema mayor; entonces podemos concluir que nuestro modelo cumple con los supuestos.

Evaluación del modelo

Similar al reporte ejecutivo pasado, supongamos que tenemos una edad y sexo fijos (a y b), esto nos da como resultado el siguiente modelo:

$$\mathbb{E}(\mu_i) = \beta_0 + \text{bmi}^2\beta_1 + \text{a}\beta_2 + \text{a}^2\beta_3 + \text{b}_2\beta_4 = \beta_0 + \text{bmi}^2\beta_1 + C$$

Como el modelo usa una función liga Identidad y bmi tiene un potencia de 2, es decir, que es positiva; podemos deducir que un índice de masa corporal elevado está asociado con una presión arterial diastólica alta, por lo tanto, tenemos que asegurarnos que Beta 1 sea positiva y haremos eso con la prueba de hipotesis siguiente:

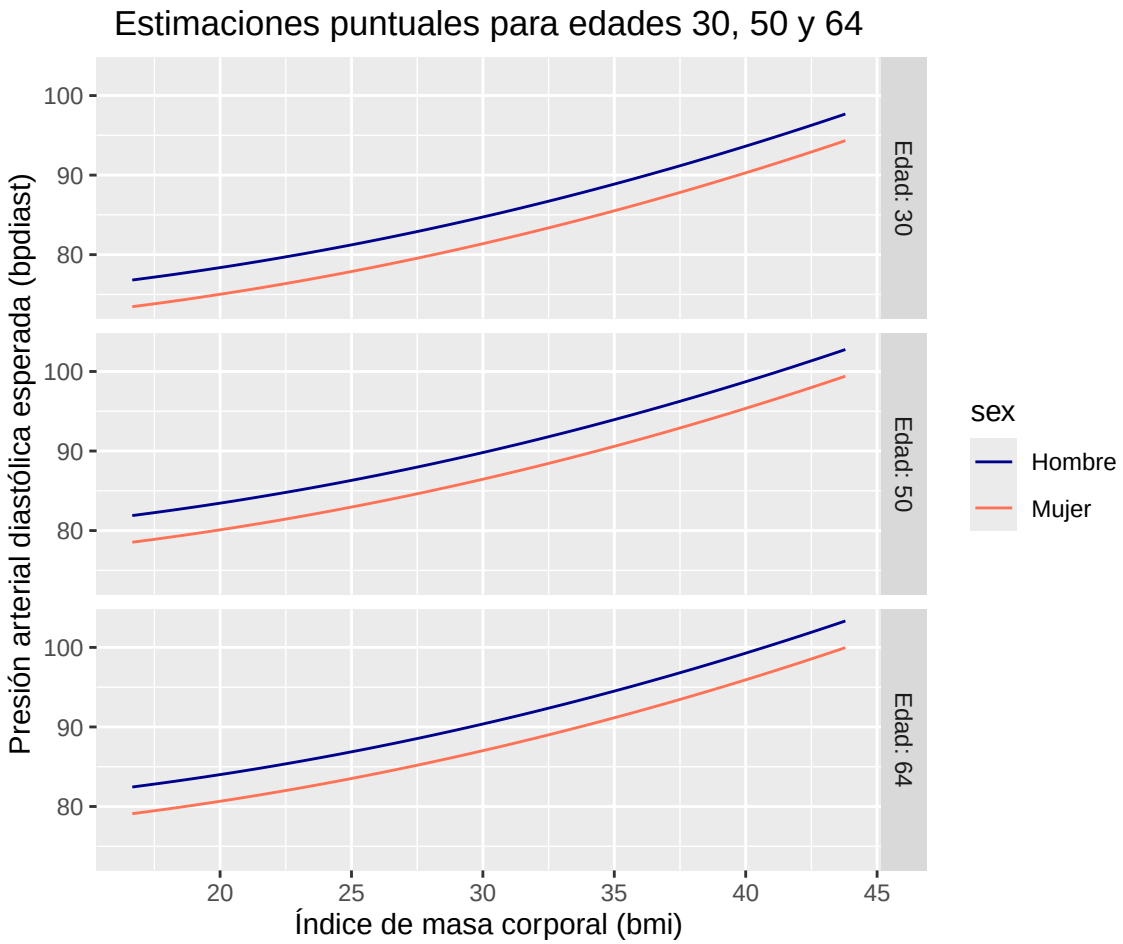
$$H_0 : \beta_1 = 0 \; vs \; H_a : \beta_1 > 0$$

La prueba de hipotesis nos da un p-value muy chico de 1.4e-08, por lo que podemos rechazar la hipótesis nula y considerar a Beta 1 mayor que 0, por lo que concluimos que un mayor índice corporal implica mayor presión arterial diastólica.

Además, obtuvimos que $\beta_1 = 0.01272$, lo que nos indica que considerando una edad y sexo específicos, por cada unidad de incremento en el índice de masa corporal, se prevé un aumento del 1.272% en la presión arterial diastólica.

Interpretación del resultado

Para ilustrar la relación estimada, presentaremos una gráfica con la estimación puntual asociada a la relación entre bpdiast y bmi, donde tomamos 3 edades especificas (30, 45 y 60) y se ve la diferencia entre hombres y mujeres.



Podemos obervar en la grafica, en las edades de 30, 50 y 64, que efectivamente la presión arterial diastólica aumenta conforme el índice de masa corporal (bmi) y tambien podemo observar que el valor de la presión arterial diastólica es mayor en hombres que en mujeres.

Comparación de modelos

Ahora, comparamos el modelo lineal generalizado encontrado con el modelo de regresión lineal múltiple usado en el reporte ejecutivo pasado principalmente para comparar las conclusiones y elegir el mejor modelo para responder la pregunta de la relación entre el índice de masa corporal y la presión arterial diastólica.

Como en el modelo de regresión lineal múltiple se aplica un logaritmo, debemos de sacar el valor del AIC de manera manual, recordemos que tenemos $Z_i = \ln(Y_i)$ con $Z_i \sim N(\mu_{z_i}, \sigma_z^2)$.

Aplicamos un cambio de variable

$$f_{Y_i}(yi; \mu_{z_i}, \sigma_z^2) = f_{Z_i}(\ln y_i) \cdot \frac{1}{y_i}$$

. La log-verosimilitud queda como

$$lv = \sum_{i=1}^{n} (ln(f_{Z_i}(\ln y_i)) - ln(y_i))$$

Finalmente el AIC queda como

$$AIC = -2(lv) + 2m = -2(lv) + 2(5+1) = -2(lv) + 12$$

Recordemos que el modelo de regresión lineal múltiple, con transformación logarítmica, tiene el AIC de valor 2668.673; mientras que el modelo lineal generalizado, con función Gamma, función liga identidad y con transformaciones en las covariables bmi y age, tiene un AIC de valor 2667.479.

Ambos modelos llegaron a la misma conclusión, que entre mayor índice corporal implica mayor presión arterial diastólica y ademas vemos que la presión arterial diastólica es mayor en hombres que en mujeres; finalmente escogemos el modelo lineal generalizado, pues tiene un AIC menor y no realiza una tranfomración logaritmica.

Ejercicio 3

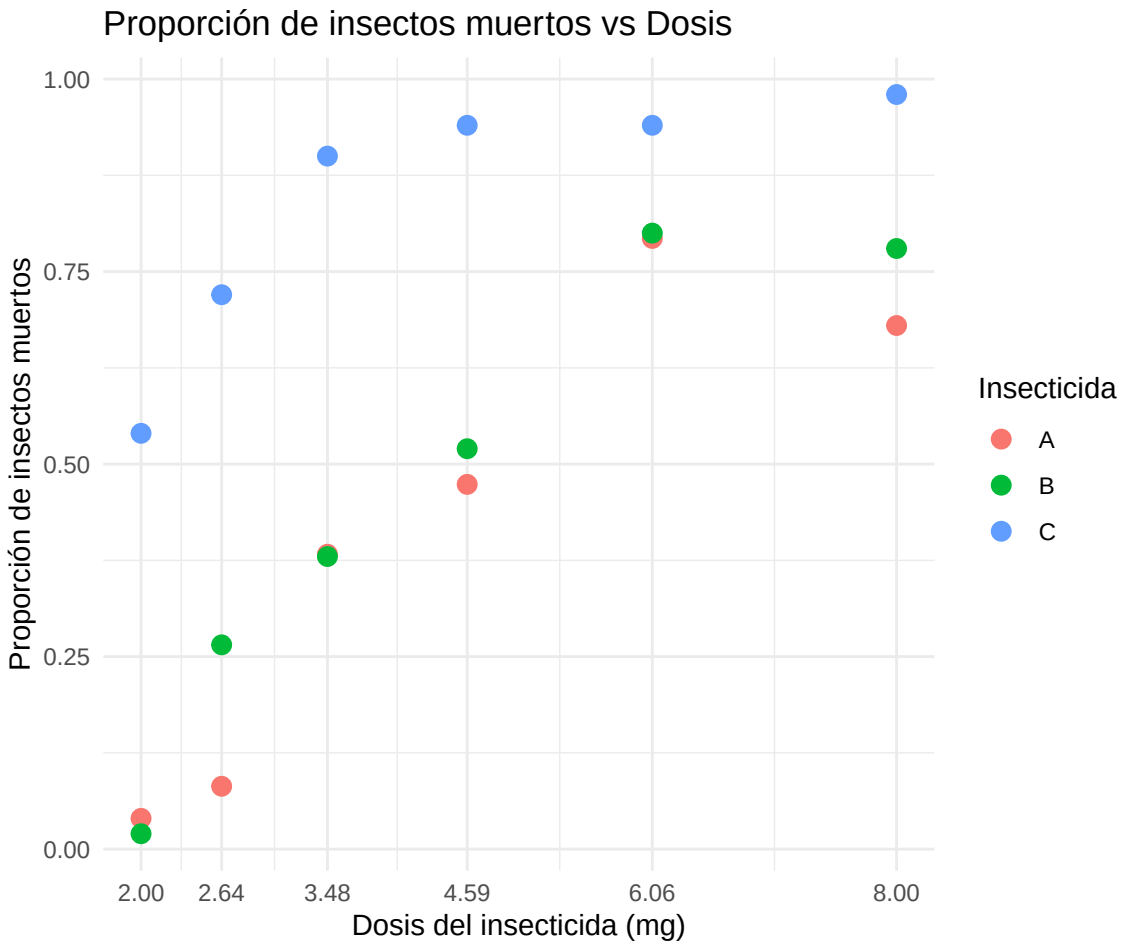
Planteamiento del Problema

La base de datos Preg3vA.csv contiene información sobre 862 insectos que fueron expuestos a diferentes dosis (Deposit, mg) de tres insecticidas (Insecticide). La asignación a una dosis y al tipo de insecticida se realizó de forma aleatoria. Después de seis días se analizó si los insectos se habían muerto, de manera que la base de datos contiene también el número de insectos muertos (Killed) y el número total de insectos expuestos (Number) por cada dosis e insecticida. Dado que se asume que el costo de los insecticidas es el mismo, el objetivo del análisis es identificar para cada insecticida qué dosis es la mínima con la que se puede indicar que el 70 % de los insectos se muere, así como si considerando la menor de esas tres dosis se puede afirmar que un insecticida es el mejor comparado con el resto. Notar que aquí el evento de interés es si el insecto muere o no. Además, dado que se tienen varios insectos para diferentes valores de dosis e insecticida, es posible realizar gráficas que ayudan a entender lo que se está modelando; de hecho la base de datos está en un formato agregado.

Solución:

Con el fin de facilitar la comprensión y el análisis del problema, se decidió desagrupar la base de datos original. Esto permitió que cada fila representara una observación individual, en la cual se registran la efectividad del insecticida (es decir, si el insecto murió o no) y la dosis aplicada. Esta transformación fue necesaria para aplicar un modelo de regresión con datos binarios de manera más entendible.

Con base en las variables de insecticida, dosis y proporción de insectos muertos, se elaboró la siguiente gráfica de dispersión, diferenciando los resultados según el tipo de insecticida.



De manera general, se observa que a medida que aumenta la dosis de insecticida, también lo hace la proporción de insectos muertos, lo que indica una relación creciente entre la dosis aplicada y la efectividad, consistente para los tres tipos de insecticida. Por otro lado, el insecticida tipo C muestra una mayor efectividad en todo el rango de dosis, ya que la proporción de insectos muertos es superior a la de los otros dos insecticidas. Los insecticidas A y B presentan un comportamiento similar; sin embargo, a partir de los 2 mg, el insecticida B parece tener una eficacia ligeramente mayor que el A. En conjunto, estos resultados sugieren que, para una misma dosis, el tipo de insecticida influye de manera significativa en la proporción de insectos muertos.

Se ajustaron modelos de regresión para datos binarios esto para relacionar la probabilidad de muerte del insecto con el tipo de insecticida, el logaritmo de la dosis aplicada y sus interacciones, facilitando así una evaluación más precisa de la efectividad de cada tratamiento. Se utilizaron las regresiones con ligas “logit”, “probit” y “cloglog”. Por lo que el componente lineal para estos tres modelos (considerando que el nivel de referencia es el insecticida A) queda dado por las siguientes expresiones:

Cuando se aplica el insecticida A, el componente lineal se expresa de la siguiente manera:

$$\eta(Insecticide = A, lnD) = \beta_0 + \beta_3 \cdot lnD,$$

Cuando es el insecticida B:

$$\eta(Insecticide = B, lnD) = \beta_0 + \beta_1 + \beta_3 \cdot lnD + \beta_4 \cdot lnD = (\beta_0 + \beta_1) + (\beta_3 + \beta_4) \cdot lnD,$$

Y cuando se trata del insecticida C:

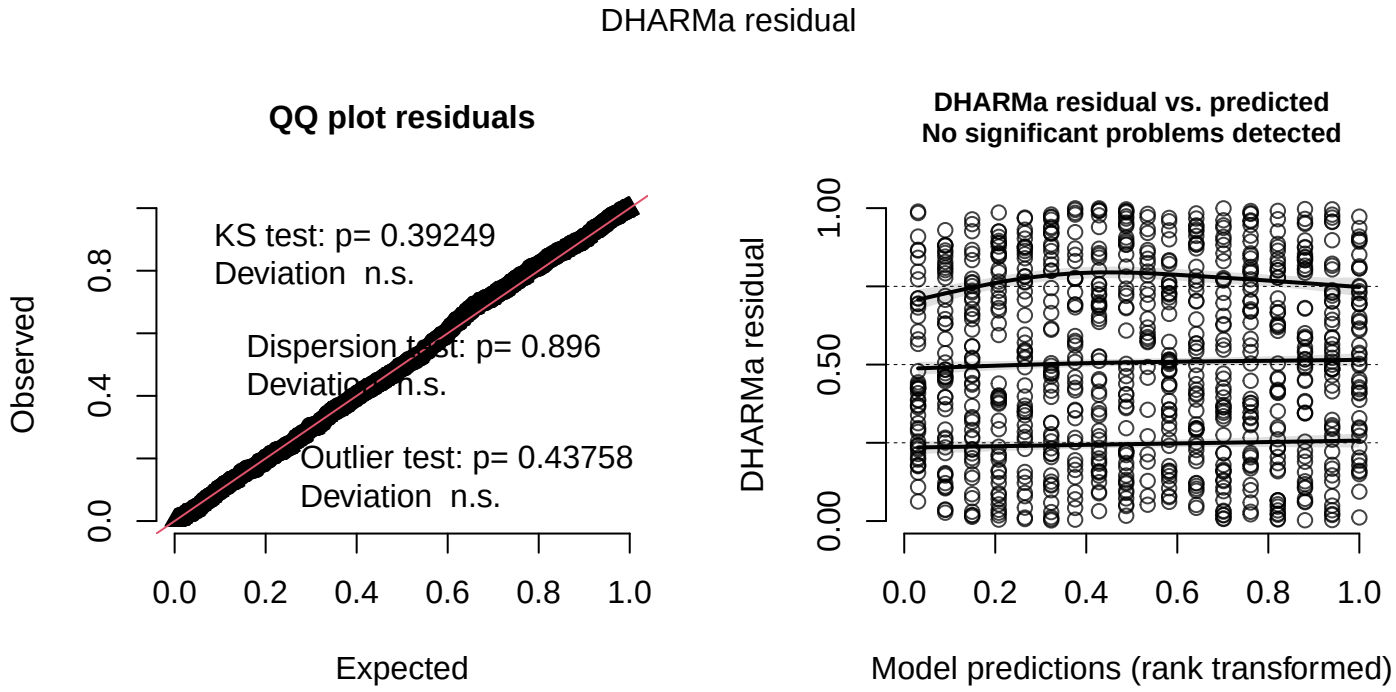
$$\eta(Insecticide = C, lnD) = \beta_0 + \beta_2 + \beta_3 \cdot lnD + \beta_5 \cdot lnD = (\beta_0 + \beta_2) + (\beta_3 + \beta_5) \cdot lnD,$$

Para determinar cuál de los modelos es más adecuado para el análisis propuesto, se emplearon los criterios de selección basados en Akaike (AIC) y Bayesiano (BIC). Los resultados obtenidos fueron los siguientes{1}:

Los resultados muestran que el modelo Probit presenta los valores más bajos de AIC y BIC, por lo que se selecciona como el modelo más adecuado para presentar la verificación de supuestos. Los resultados muestran claramente que el modelo Probit presenta los valores más bajos de AIC y BIC, por lo que se selecciona este modelo para la verificación de supuestos. Para ello, se emplearon únicamente los residuales simulados generados con la paquetería DHARMa, obteniéndose los siguientes resultados:

Table 1: Criterios de información.

Modelo	AIC	BIC
Logit	809.42	837.97
Probit	809.13	837.69
Cloglog	821.88	850.43



Los resultados del análisis de residuales indican que el modelo presenta un ajuste adecuado. En el QQplot, los residuales se alinean de manera satisfactoria con la distribución teórica, lo que sugiere un buen nivel de ajuste. Asimismo, las pruebas estadísticas (KS, dispersión y valores atípicos) confirman que la varianza está correctamente modelada y no se detectan observaciones atípicas. En conjunto, los residuales simulados de DHARMa muestran un comportamiento óptimo, sin anomalías relevantes, aunque podría explorarse una mejora del modelo incorporando interacciones cuadráticas con lnD^2, lo que se hace a continuación.

Veamos como se describe la componente lineal de esta nueva modelación:

$$\eta(Insecticide = A, lnD) = \beta_0 + \beta_3 \cdot lnD + \beta_4 \cdot lnD^2,$$

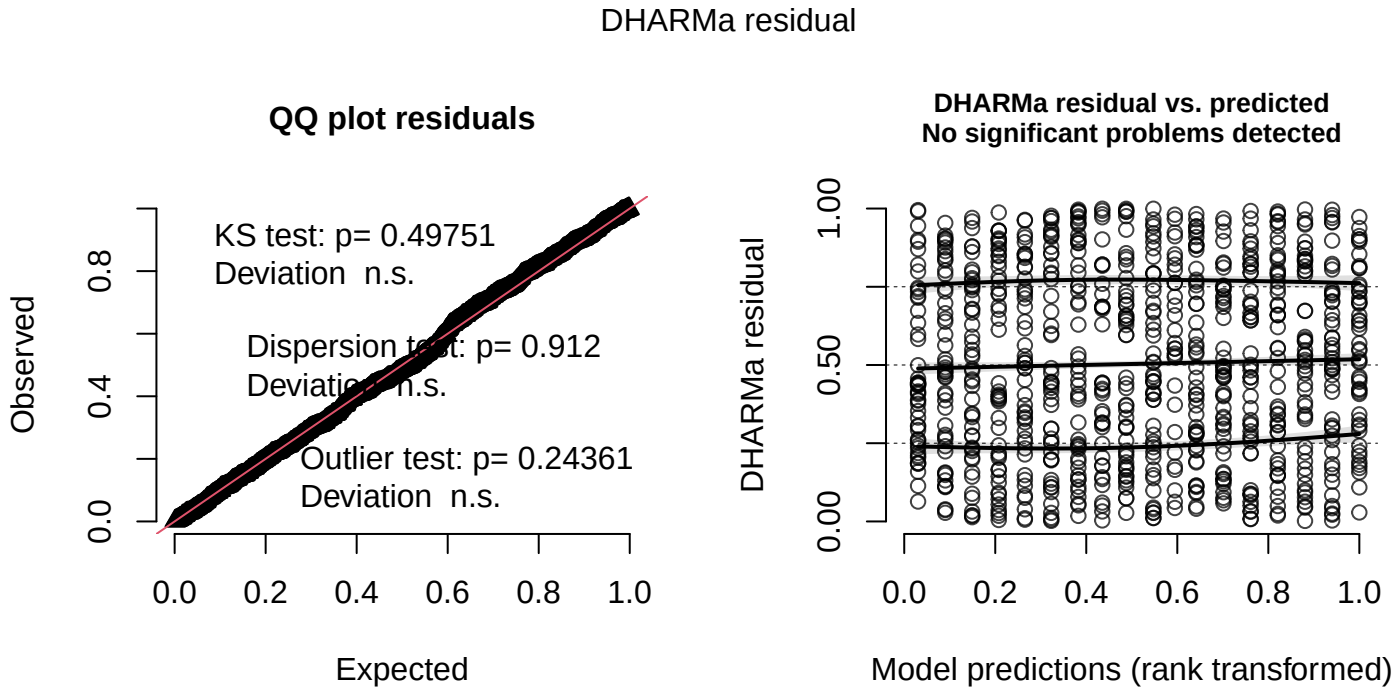
$$\eta(Insecticide = B, lnD) = \beta_0 + \beta_1 + \beta_3 \cdot lnD + \beta_4 \cdot lnD^2 + \beta_5 \cdot lnD + \beta_7 \cdot lnD^2 = (\beta_0 + \beta_1) + (\beta_3 + \beta_5) \cdot lnD + (\beta_4 + \beta_7) \cdot lnD^2,$$

$$\eta(Insecticide = C, lnD) = \beta_0 + \beta_2 + \beta_3 \cdot lnD + \beta_4 \cdot lnD^2 + \beta_6 \cdot lnD + \beta_8 \cdot lnD^2 = (\beta_0 + \beta_2) + (\beta_3 + \beta_6) \cdot lnD + (\beta_4 + \beta_8) \cdot lnD^2,$$

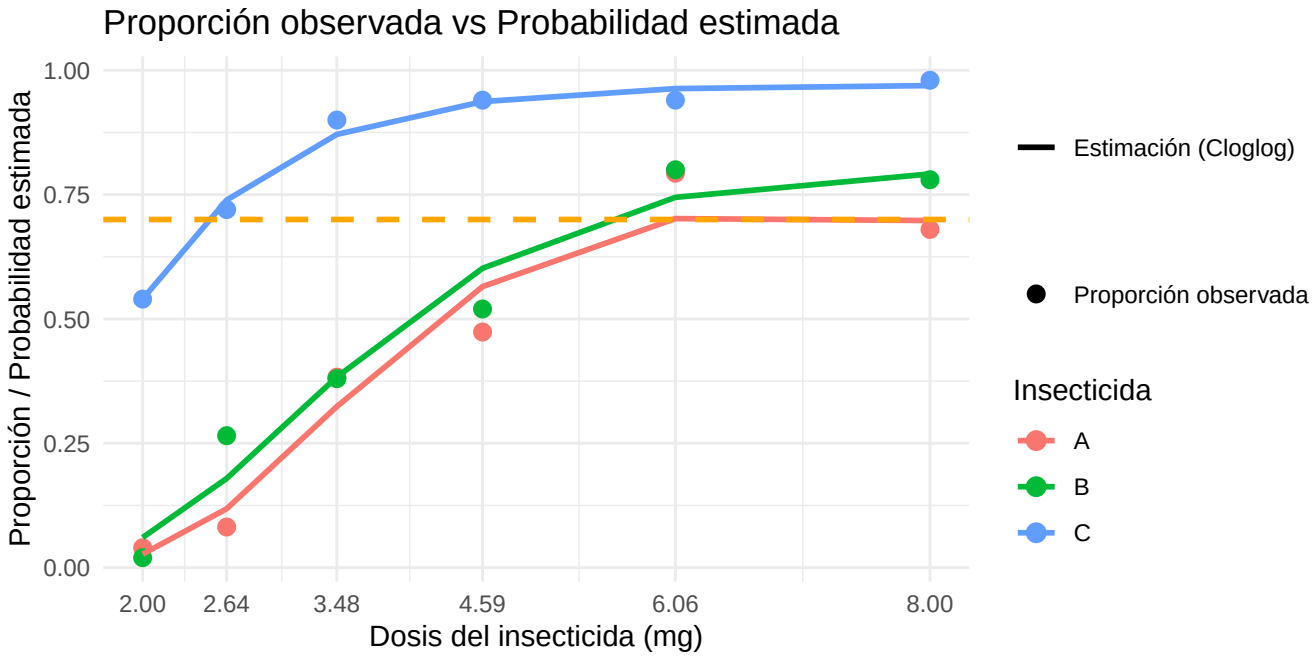
Luego utilizando los criterios de akaike y bayesiano{2} se tiene que el mejor modelo es el cloglog, por lo que se realizaron las pruebas de hipótesis con la simulaciones de los residuales:

Table 2: Criterios de información.

Modelo	AIC	BIC
Logit	803.09	845.93
Probit	803.1	845.93
Cloglog	802.83	845.66



Al realizar las pruebas de hipótesis mediante la simulación de residuales, se observa una mejora en el comportamiento del componente lineal, sin que se rechace ninguna de las pruebas de ajuste. Por lo tanto, este modelo puede considerarse adecuado y se selecciona como el más indicado entre los seis modelos evaluados. A continuación, se comparan las probabilidades estimadas con los datos observados en la gráfica inicial.



El modelo proporciona estimaciones precisas. Se incluye una línea horizontal en 0.7 para visualizar que todas las curvas alcanzan ese nivel. Analíticamente, la dosis mínima que garantiza la muerte del 70% de los insectos se obtiene aplicando la función liga a 0.7 y resolviendo las siguientes ecuaciones del componente lineal para cada insecticida, obteniendo así D para A, B y C.

$$\eta(A, ln(D)) = -9.072 + 9.629 \cdot lnD + (-2.491) \cdot lnD^2 = ln(-ln(1-0.7)),$$

$$\eta(B, ln(D)) = -6.759 + 6.891 \cdot lnD + (-1.647) \cdot lnD^2 = ln(-ln(1-0.7)),$$

$$\eta(C, ln(D)) = -2.16 + 3.308 \cdot lnD + (-0.803) \cdot lnD^2 = ln(-ln(1-0.7)),$$

Table 3: Dosis Mínimas.

Insecticida	Dosis Mínima (mg)
A	6.01
B	5.43
C	2.48

Para la dosis mínima estimada de (2.48 mg){3} queremos evaluar si el insecticida C es más efectivo que los otros dos. Es decir, considerando Y como la variable aleatoria que toma 1 si el insecto muere y 0 si no, planteamos el contraste de hipótesis correspondiente

$$P(Y=1|Insec=A, D=2.48) < P(Y=1|Insec=C, D=2.48) \cap P(Y=1|Insec=B, D=2.48) < P(Y=1|Insec=C, D=2.48)$$

O bien en términos del componente lineal (creciente) y aplicando las pruebas de hipótesis múltiples se llega a:

$$\begin{aligned}
\eta(Insect=C, D=2.48) &> \eta(Insect=A, D=2.48) \\
\beta_0+\beta_2+(\beta_3+\beta_6)\ln D+(\beta_4+\beta_8)(\ln D)^2 &> \beta_0+\beta_3\ln D+\beta_4(\ln D)^2 \\
\beta_2+\beta_6\ln 2.48+\beta_8(\ln 2.48)^2 &> 0
\end{aligned}$$

$$\begin{aligned}
\eta(Insect=C, D=2.48) &> \eta(Insect=B, D=2.48) \\
\beta_0+\beta_2+(\beta_3+\beta_6)\ln D+(\beta_4+\beta_8)(\ln D)^2 &> (\beta_0+\beta_1)+(\beta_3+\beta_8)\ln D+(\beta_4+\beta_7)(\ln D)^2 \\
(\beta_2-\beta_1)+(\beta_6-\beta_5)\ln 2.48+(\beta_8-\beta_7)(\ln 2.48)^2 &> 0
\end{aligned}$$

Hipótesis	P-value
P(Y=1|Insec = A, D=2.48)<P(Y=1|Insec = C, D=2.48)	$1.1546319 \times 10^{-13}$
P(Y=1|Insec = B, D=2.48)<P(Y=1|Insec = C, D=2.48)	3.6746049×10^{-5}

Por lo tanto, se rechazan ambas hipótesis, lo que indica que existe evidencia suficiente para concluir que el insecticida C es más efectivo con una dosis de 2.48 mg. Finalmente, observando la gráfica inicial, se aprecia que el comportamiento de la proporción de mortalidad para los insecticidas A y B es similar; a partir de ello, es posible plantear una prueba de hipótesis simultanea para evaluar formalmente esta similitud, se tendría que comprobar con cada una de las dosis, de la siguiente forma:

$$\begin{aligned}
\eta(\text{Insec}=A, \text{Deposit}) &= \eta(\text{Insec}=B, \text{Deposit}) \\
\beta_0+\beta_3\ln D+\beta_4(\ln D)^2 &= (\beta_0+\beta_1)+(\beta_3+\beta_5)\ln D+(\beta_4+\beta_7)(\ln D)^2 \\
\beta_1+\beta_5\ln D+\beta_7(\ln D)^2 &= 0
\end{aligned}$$

Así utilizando nuevamente el paquete multcomp se tiene para cada diferente dosis (mg):

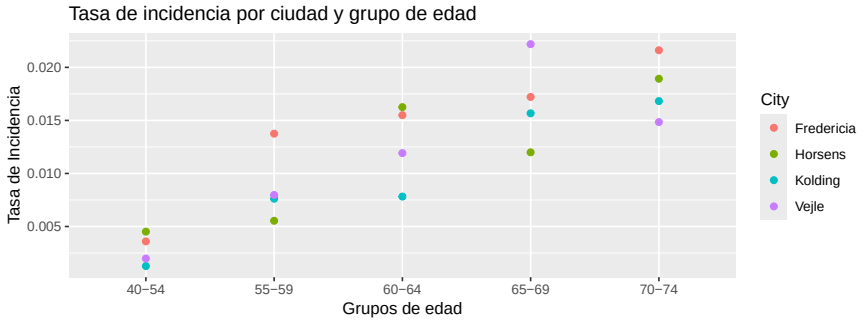
```
## [1] 0.6203582 0.5466138 0.7320140 0.9559993 0.8879841 0.6470820
```

Los resultados del modelo indican que, dado que todos los p-values ajustados superan el nivel de significancia establecido, no existe evidencia estadísticamente significativa para rechazar la hipótesis de igualdad entre las probabilidades de mortalidad de los insecticidas A y B. En otras palabras, ambos insecticidas presentan un comportamiento similar en términos de efectividad a la dosis analizada.

Adicionalmente, se reconoce que el análisis podría complementarse explorando alternativas metodológicas, como la reducción de variables o la implementación de una malla más detallada para la variable continua, lo cual permitiría una evaluación más robusta del modelo y de las posibles diferencias entre tratamientos.

La base de datos Preg4.csv contiene información sobre el número de casos de cáncer de pulmón (Cases) registrados entre 1968 y 1971 en cuatro cuidades de Dinamarca (City). En estos casos se registró también la edad de los pacientes (Age, variable categorizada en 5 grupos). El interés del análisis es estudiar si se puede indicar que a mayor edad existe mayor incidencia de cáncer de pulmón.

Veamos como se ve una gráfica de nuestros datos, donde hacemos la distinción entre ciudades y grupos de edad.



Vemos que en nuestra gráfica podemos notar una ligera tendencia creciente en cuanto al registro de los casos de cancer de pulmón, lo unico raro que podemos observar en cuanto al tipo de cancer Vejle es que en los grupos de edad 65-69 se registraron más casos que en el grupo de 70-74, pero en general se puede observar una tendencia a la alza.

Haremos el ajuste de dos modelos, en el primero usaremos como variables explicativas a la edad y la ciudad, mientras que en el segundo modelo que vamos a ajustar usaremos solo la variable de edad.

Tenemos que al hacer el ajuste de cada modelo, el primer modelo que incluye interacciones tiene muchos parámetros, lo cual lo hace un modelo más complejo para trabajar. Entonces haremos una prueba de hipotesis que nos permita decidir si podemos usar el modelo 2 que no contiene a estas interacciones.

```
## Analysis of Deviance Table
##
## Model 1: Cases ~ Age * City + offset(log_pop)
## Model 2: Cases ~ Age + offset(log_pop)
##   Resid. Df Resid. Dev  Df Deviance Pr(>Chi)
## 1         0      0.000
## 2        15     16.978 -15  -16.978   0.3202
```

Al hacer una prueba de hipotesis tenemos que la prueba Chi cuadrada no rechaza H_o por lo que es plausible usar el modelo reducido,el que tiene solo la variable edad.

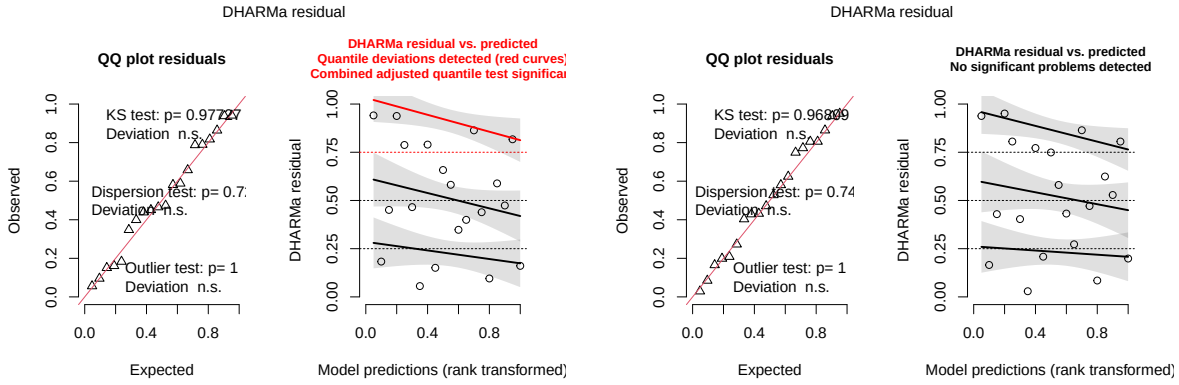
También podemos ver que en cuanto al AIC y BIC el modelo que no contiene interacciones es mejor.

Modelo	AIC	BIC
Age * City	121.4730	141.3876
Age	108.4512	113.4299

Ahora, podemos ajustar un tercer modelo con una distribución binomial negativa para ver cual funciona mejor para nuestro ajuste.

Para decidir con cual quedarnos primero veamos si cumplen los supuestos para cada modelo que tenemos.

Veamos unas gráficas para la verificación de supuestos:



Vemos que para el modelo Poisson en la parte del componente lineal hay un pequeño problema con el cuartil de 0.75, pero nada grave, por lo que podemos usar

Ahora veamos los AIC y BIC de los modelos:

Modelo	AIC	BIC
Poisson	108.4512	113.4299
BN	110.4515	116.4259

Vemos que tanto el AIC y BIC del modelo Poisson son más pequeños, pero en cuanto a los supuestos la Binomial Negativa los cumple de mejor manera, esto nos ayuda a que se modele con un poco más de presición nuestra esperanza, por lo que usaremos el modelo de la Binomial Negativa. Cabe resaltar que aunque el AIC y BIC sean más pequeños la diferencia es mínima, entonces no supone un problema mayor usar la Binomial Negativa.

Ahora para poder calcular los intervalos de confianza veamos como se ve el modelo para cada categoría.

Tenemos que el modelo completo es de la forma:

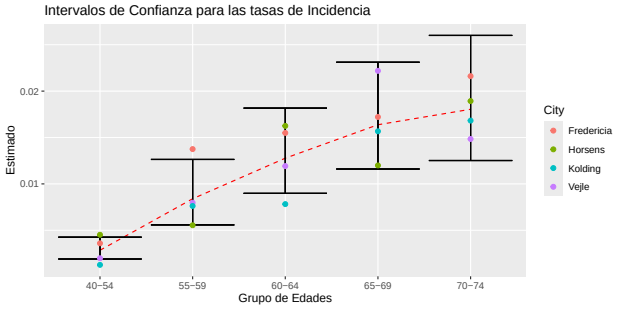
$$ln\left(\frac{\mathbf{E}\left[y\ ;\ Age\right]}{pop}\right) = \beta_0 + \beta_1 \mathbb{I}_{Age=55-59} + \beta_2 \mathbb{I}_{Age=60-64} + \beta_3 \mathbb{I}_{Age=65-69} + \beta_4 \mathbb{I}_{Age=70-74}$$

Ahora fijando valores para cada valor de edad tenemos:

$$ln\left(\frac{\mathbf{E}\left[y\ ;\ Age = \text{40-54}\right]}{pop}\right) = \beta_0, \quad ln\left(\frac{\mathbf{E}\left[y\ ;\ Age = \text{55-59}\right]}{pop}\right) = \beta_0 + \beta_1, \quad ln\left(\frac{\mathbf{E}\left[y\ ;\ Age = \text{60-64}\right]}{pop}\right) = \beta_0 + \beta_2$$

$$ln\left(\frac{\mathbf{E}\left[y\ ;\ Age = \text{65-69}\right]}{pop}\right) = \beta_0 + \beta_3, \quad ln\left(\frac{\mathbf{E}\left[y\ ;\ Age = \text{70-74}\right]}{pop}\right) = \beta_0 + \beta_4$$

Ahora veamos una gráfica de las estimaciones de los intervalos de confianza:



Con está gráfica vemos que para el primer grupo de edad nuestros intervalos de confianza no se traslapan con el siguiente grupo de edad, por lo que para este grupo podemos decir que a más edad hay más casos de incidencia de cancer.

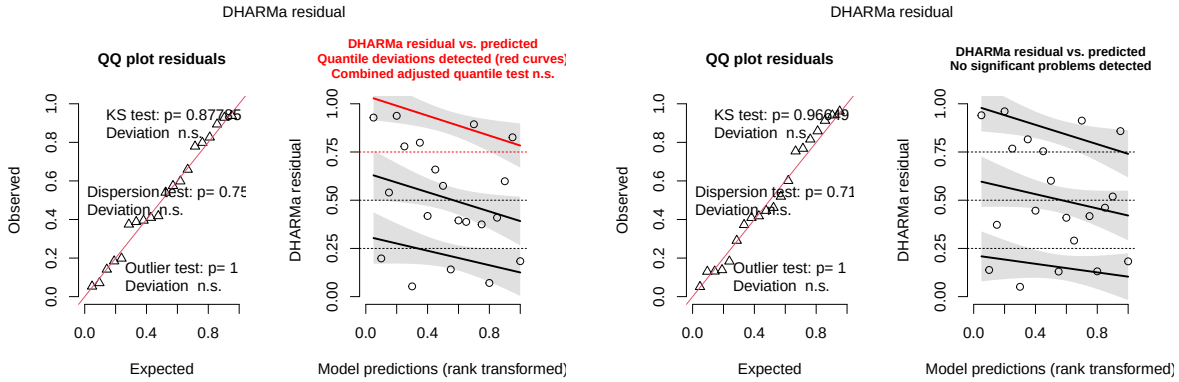
En cuanto a los demás grupos de edad, vemos que todos los intervalos de llegan a traslapar, incluso el segundo grupo llega a traslaparse con el último grupo, por lo que no podemos concluir que para los demás grupos de tenga que a mayor edad más casos de incidencia del cancer. También podemos decir que no hay una relación en cuanto a las ciudad donde se reportaron los casos, por lo que fue correcto modelar nuestra esperanza solo con la variable Age.

Ahora usaremos los datos de la variable Age como si fueran edades puntuales, en vez de un rango de edades.

Vamos a ajustar cuatro modelos para esta nueva variable Ageprima, dos con solo la Ageprima, y otros 2 tomando en cuenta a la variable Ageprima al cuadrado y vamos a ver cual de estos modelos nos sirve.

Llegamos a la conclusión de que los primeros dos modelos no cumplen los supuestos, aunque las pruebas de hipotesis no se rechazan, vemos que la parte lineal no es la adecuada para hacer nuestro modelo, por lo que no podemos usarlos para nuestro análisis.

Ahora veamos los supuestos para los modelos con la variable cuadrática:



Al igual que en los primeros modelos vemos que ambos modelos cumplen los modelos, en el Poisson vemos la parte lineal tiene un pequeño problema igual en el cuartil del 0.75, pero podemos usar el modelo. Y con el Binomial Negativo vemos que los supuestos se cumplen mejor que la Poisson.

Veamos una tabla comparando los valores del AIC y BIC:

Modelo	AIC	BIC
Poisson	108.4512	113.4299
BN	110.4515	116.4259
Poisson Ageprima^2	104.5095	107.4967
BN Ageprima^2	106.5098	110.4927

Como en los primeros modelos que propusimos, vemos que el modelo Poisson tiene mejor AIC y BIC pero tiene la misma condición de los supuestos, y en la Binomial Negativa los supuestos se cumplen mejor, por lo que para este caso también usaremos el modelo de la Binomial Negativa.

Ahora para contestar si a mayor edad hay mayor incidencia del cancer, vamos a ver como se ven nuestras expresiones de este nuevo modelo.

$$ln\left(\frac{\mathbf{E}\left[y\ ;\ Age\right]}{pop}\right) = \beta_0 + \beta_1 Ageprima + \beta_2 Ageprima^2$$

Ahora para ver si conforme pasan los años hay más casos, vamos a analizar la primera derivada de nuestra expresión, pues si la derivada es positiva podemos decir que hay una relación creciente para nuestro modelo.

Por lo que haremos pruebas de hipótesis simultaneas para ver donde la derivada es positiva, y haremos una gráfica para ver en que punto deja de ser positiva.

La derivada es:

$$\frac{\partial}{\partial Age} ln\left(\frac{\mathbf{E}\left[y\ ;\ Age\right]}{pop}\right) = \frac{\partial}{\partial Age}(\beta_0 + \beta_1 Ageprima + \beta_2 Ageprima^2) = \beta_1\ +\ 2\beta_2 Ageprima$$

Ahora queremos ver en que momento esta derivada deja de ser mayor que 0, pues esto nos diría en que intervalos podemos decir que se cumple que a mayor edad más incidencia.

Primero veamos si es que los extremos de nuestro intervalo de edades cumplen que la derivada sea mayor que 0, pues esto nos diria que todo el intervalo cumple esta condición, por lo que haremos una prueba de hipotesis donde el contraste es:

$$H_o : \beta_1\ +\ 2\beta_2 Ageprima \leq 0 \quad vs \quad H_a : \beta_1\ +\ 2\beta_2 Ageprima > 0$$

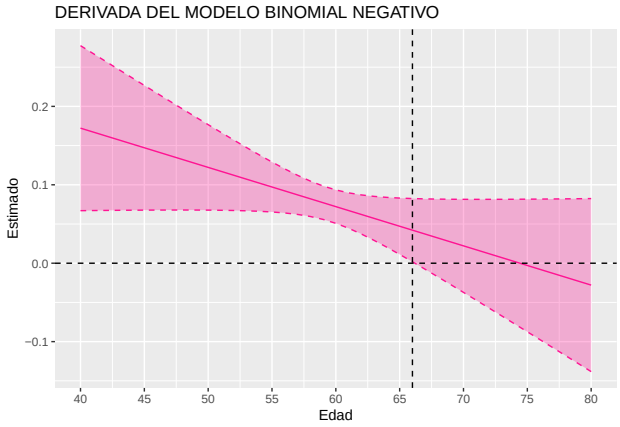
Donde nosotros queremos rechazar H_o para que nuestra relación sea creciente.

Entonces hagamos la prueba de hipotesis.

```
##
##   Simultaneous Tests for General Linear Hypotheses
##
## Fit: glm.nb(formula = Cases ~ Ageprima + I(Ageprima^2) + offset(log_pop),
##     data = datos, link = "log", init.theta = 151985.2475)
##
## Linear Hypotheses:
##        Estimate Std. Error z value Pr(>|z|)
## 1 == 0  0.17223    0.04306   4.000  0.00011 ***
## 2 == 0  0.01211    0.02837   0.427  0.81019
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## (Adjusted p values reported -- single-step method)
```

Vemos que para la edad de 40 se cumple que la pendiente es positiva, entonces hay una relación creciente, pero para nuestra edad 70 no se rechaza la hipotesis nula, por lo que no podemos decir que todo nuestro intervalo sea siempre creciente.

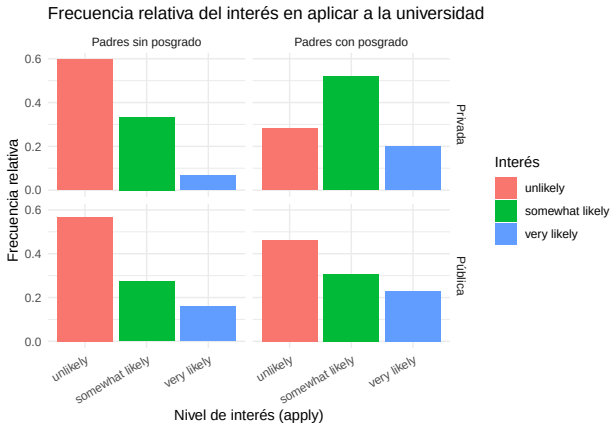
Entonces haremos intervalos de confianza para ver donde se deja de cumplir esto.



Podemos observar que en la gráfica los intervalos de confianza de 40 hasta 66 años están por arriba del 0, lo que nos indidica que para este rango de edad podemos decir que hay una relación creciente, pero a partir de los 66 años los intervalos de confianza están por debajo de 0, lo cual nos indica que no hay un comportamiento creciente para los casos de incidencia.

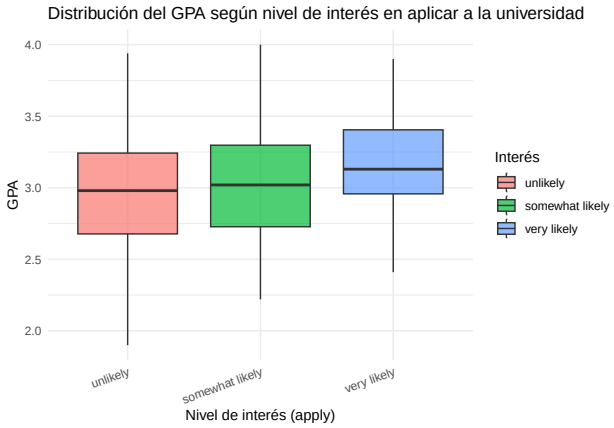
Entonces con esto podemos concluir que para edad 40 a 66 a mayor edad existe mayor incidencia de cancér de pulmón, mientras que para las edades mayores de 66 no podemos concluir lo mismo.

La base de datos Preg5.csv contiene información sobre el interés de aplicar a una maestría o doctorado (apply: unlikely, somewhat likely, very likely) de una muestra aleatoria de 400 estudiantes de universidad. El interés es identificar si entre los factores que definen este interés están: el tipo de universidad (public: 1 public, 0 private), si alguno de los padres estudió un posgrado (pared: 1 sí, 0 no) y el promedio actual en sus estudios universitarios (gpa). Primero obtengas un contexto general de como se encuentran distribuidas en frecuencia las dos variables categóricas las cuales son si sus padres estudiaron un posgrado y si estudian en una universidad publica o privada con respecto a nuestra variable de interés que es su nivel de interés de aplicar a una maestría o posgrado, por lo cual hagamos un grafico de frecuencia relativa es decir $\frac{Frc(x_i)}{Frc(total)}$



Podemos observar, como primera impresión, que la mayoría de las personas del estudio presentan una baja probabilidad de realizar estudios de posgrado. Sin embargo, esta tendencia cambia en el caso de quienes estudian en una universidad privada y cuyos padres cuentan con estudios de posgrado. Asimismo, se aprecia que las respuestas "muy probable" y "algo probable" aumentan cuando los padres tienen formación de posgrado y aun mas si los estudiantes asisten a una institución privada.

De igual forma para la otra variable que tenemos la cual es el promedio actual del alumno la cual es continua para ello usemos un gráfico de box-plot para visualizar la calificación media de acuerdo al nivel de interés de aplicar a una maestría



Se observa que a medida que aumenta el nivel de interés en aplicar a la universidad, también tiende a incrementarse el promedio académico (GPA) de los estudiantes. En particular, quienes manifiestan un alto interés ("very likely") presentan una mediana de GPA ligeramente superior en comparación con los grupos "somewhat likely" y "unlikely". Esto sugiere una posible relación positiva entre el rendimiento académico y la intención de continuar con los estudios universitarios.

Ahora ajustaremos un modelo multinomial considerando las tres variables disponibles. Para encontrar el modelo más adecuado y, al mismo tiempo, simplificar su estructura, estimaremos cuatro modelos con distintos niveles de complejidad: desde el modelo completo con interacciones de tercer orden, pasando por interacciones de segundo orden, hasta un modelo con solo efectos principales y, finalmente, uno con solo el Intercepto para verificar si vale la pena ajustar un modelo.

Para posteriormente realizar una pueda una prueba anova la cual nos permite determinar mediante una prueba de hipótesis si podemos trabajar con un modelo mas reducido al que tenemos ya que

$$H_0: \text{ Podemos utilizar el modelo reducido}$$

vs.

$$H_a: \text{ Debemos utilizar el modelo completo}$$

```
## Analysis of Deviance Table
##
## Model 1: apply ~ 1
## Model 2: apply ~ pared * public * gpa
##   Resid. Df Resid. Dev Df Deviance  Pr(>Chi)
## 1       798     741.21
## 2       784     701.16 14    40.04 0.0002514 ***
```

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

## Analysis of Deviance Table
##
## Model 1: apply ~ pared * public * gpa
## Model 2: apply ~ pared * public + pared * gpa + public * gpa
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1       784     701.16
## 2       786     702.06 -2 -0.89792   0.6383

## Analysis of Deviance Table
##
## Model 1: apply ~ pared * public * gpa
## Model 2: apply ~ pared + public + gpa
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1       784     701.16
## 2       792     713.99 -8  -12.829   0.1179
```

Primero, verificamos el modelo con solo el intercepto en comparación con el modelo más completo, que incluye las interacciones de tercer orden. En este caso, rechazamos la hipótesis nula, por lo que debemos utilizar el modelo completo.

Posteriormente, comparamos el modelo completo con aquel que considera únicamente interacciones de segundo orden. En esta comparación, no se rechaza la hipótesis nula, lo que indica que podemos trabajar con el modelo reducido.

Finalmente, comparamos este modelo con otro que solo incluye los efectos principales (sin interacciones entre las variables). Nuevamente, no se rechaza la hipótesis nula, por lo que es posible trabajar con el modelo aún más reducido.

Por otro lado, apliquemos un modelo de regresión ordinal primero considerando u modelo sin proporcionalidad en las variables, y otro donde si la tenga, y como en caso anterior de la regresión logística, apliquemos un modelo con solo el intercepto para verificar si nuestro modelado es adecuado.

```
## Analysis of Deviance Table
##
## Model 1: apply ~ 1
## Model 2: apply ~ pared + public + gpa
##   Resid. Df Resid. Dev Df Deviance  Pr(>Chi)
## 1       798     741.21
## 2       792     713.01  6   28.194 8.637e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

## Analysis of Deviance Table
##
## Model 1: apply ~ 1
## Model 2: apply ~ pared + public + gpa
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1       798     741.21
## 2       795     717.02  3    24.18 2.29e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
## Analysis of Deviance Table
##
## Model 1: apply ~ pared + public + gpa
## Model 2: apply ~ pared + public + gpa
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1       792     713.01
## 2       795     717.02 -3  -4.0138     0.26
```

De igual forma usando la tabla anova y comparando los modelos, asiéndolo del modelo más complejo al modelo reducido que en este caso es el proporcional obtenemos que podemos que podemos trabajar con este.

Y para determinar nuestro modelo que usaremos comparando mediante el AIC y el BIC el mejor modelo obtenido mediante la regresión logística y la regresión logística multinomial

```
## [1] 727.0249
```

```
## [1] 729.994
```

```
## [1] 746.9822
```

```
## [1] 761.9257
```

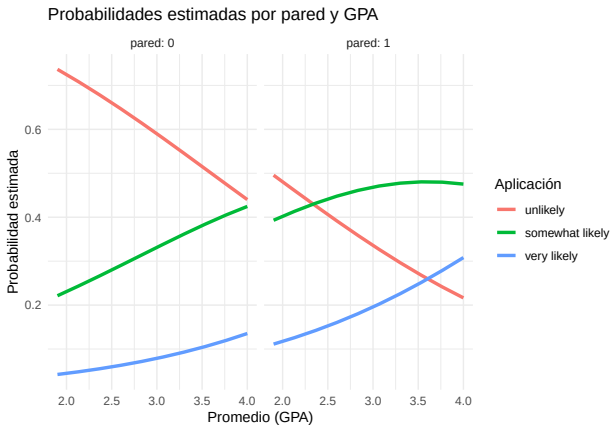
```
##
## Call:
## vglm(formula = apply ~ pared + public + gpa, family = cumulative(parallel = TRUE),
##     data = datos)
##
## Coefficients:
##               Estimate Std. Error z value Pr(>|z|)
## (Intercept):1  2.20335    0.78440   2.809  0.00497 **
## (Intercept):2  4.29879    0.80915   5.313 1.08e-07 ***
## pared1        -1.04766    0.26845  -3.903 9.52e-05 ***
## public1        0.05867    0.28861   0.203  0.83891
## gpa           -0.61575    0.26258  -2.345  0.01903 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Names of linear predictors: logitlink(P[Y<=1]), logitlink(P[Y<=2])
##
## Residual deviance: 717.0249 on 795 degrees of freedom
##
## Log-likelihood: -358.5124 on 795 degrees of freedom
##
## Number of Fisher scoring iterations: 4
##
## No Hauck-Donner effect found in any of the estimates
##
##
## Exponentiated coefficients:
##    pared1   public1       gpa
## 0.3507593 1.0604268 0.5402335
```

Después de ver el summary, podemos y de las betas asociadas a cada variable, donde podemos identificar que la variable asociada a si los alumnos asisten a una universidad publica no es significativa para la modelo dada las demás variables por lo que optaremos por sacarla del modelo

```
## Analysis of Deviance Table
##
## Model 1: apply ~ pared + gpa
## Model 2: apply ~ pared + public + gpa
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1       796     717.06
## 2       795     717.02  1 0.038917   0.8436
```

Verificando con la prueba anova, vemos que podemos trabajar con el modelo solo considerando las variables de pared y gpa.

Ahora graficando nuestros datos y comparándolos con los datos de los que partimos .



En términos generales, en el modelo podemos apreciar que los estudiantes cuyos padres no tienen estudios de posgrado (pared = 0), se observa que a medida que aumenta el GPA, disminuye la probabilidad de no estar interesado en continuar estudios de posgrado (unlikely), mientras que aumenta la probabilidad de estar muy interesado (very likely). Esto sugiere que un mejor desempeño académico se asocia con una mayor disposición a continuar con formación avanzada Por otro lado, entre los estudiantes con al menos un padre con estudios de posgrado (pared = 1), las probabilidades de mostrar interés (somewhat likely o very likely) son más altas en todos los niveles de GPA, y la probabilidad de desinterés (unlikely) es consistentemente menor. Esto indica que el antecedente educativo de los padres ejerce una influencia positiva en la intención de realizar estudios de maestría o doctorado, incluso cuando el promedio académico no es particularmente alto. En conjunto, los resultados sugieren que tanto el desempeño académico como el contexto educativo familiar son factores relevantes en la decisión de continuar con estudios de posgrado, y que el modelo ordinal captura adecuadamente esta relación.