

UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

FACULTAD DE CIENCIAS



SEMINARIO DE ESTADÍSTICA I

TAREA 2:
SELECCIÓN DE VARIABLES, BOOTSTRAP Y APRENDIZAJE NO SUPERVISADO

Profesor: Gonzalo Pérez de la Cruz
Ayudante: César Humberto Valle Márquez
Grupo: 9275

Alumno:

- Alvarado Eriza Yael Jesús
- Castro Telles Omar Tadeo
- Méndez García Efrén
- Romero Medina Emiliano
- Santos Zavala Javier Eduardo

Resumen Ejecutivo 1

El presente reporte detalla el análisis de la estimación del parámetro $\tau(\theta) = P(X = 0) = e^{-\theta}$ para una muestra de variables aleatorias $X_1, \ldots, X_n$ independientes e idénticamente distribuidas (i.i.d.) siguiendo una distribución Poisson con parámetro θ. La estimación se realiza utilizando el estimador UMVUE, denotado como $\tau = \left(1 - \frac{1}{n}\right)^{\sum_{i=1}^{n} X_i}$.

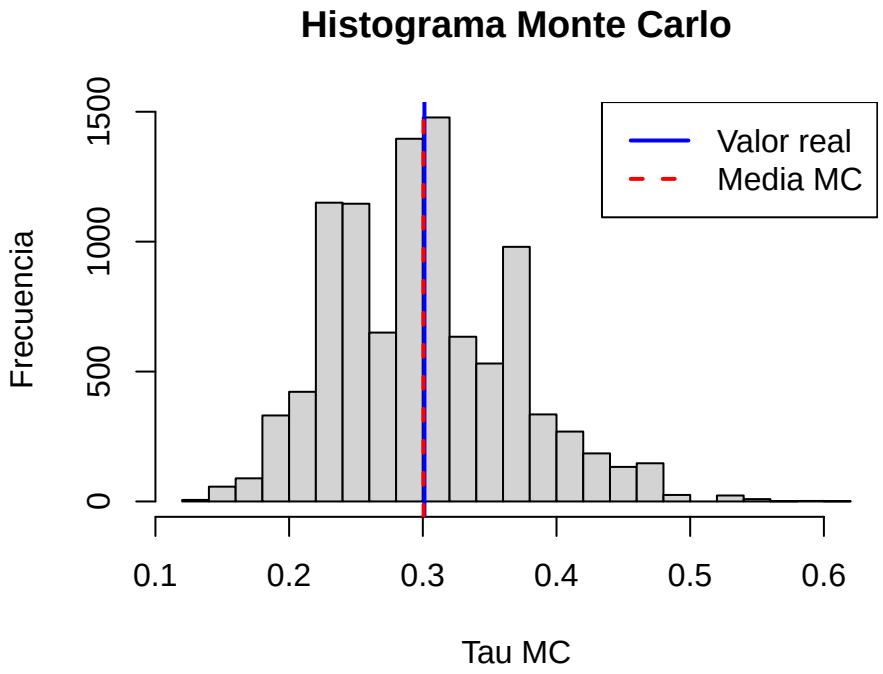
El valor real del parámetro es $\tau = e^{-1.2} \approx 0.3011942$.

El estudio se estructura en tres componentes principales: Aproximación por Simulación Monte Carlo: Se utilizan $B = 10000$ réplicas con $\theta = 1.2$ y un tamaño de muestra $n = 25$ para estimar la esperanza $\mathbb{E}[\hat{\tau}]$ y la varianza $\text{Var}(\hat{\tau})$ del estimador, obteniendo los siguientes resultados:

Table 1: Resultados Monte Carlo

Estadístico	Valor
Media MC	0.300568
Varianza MC	0.004422
Valor Real e^{-theta}	0.301194

Se puede considerar que esta aproximación es muy buena, ya que se acerca al valor teórico esperado, lo cual se corrobora al observarla gráficamente.

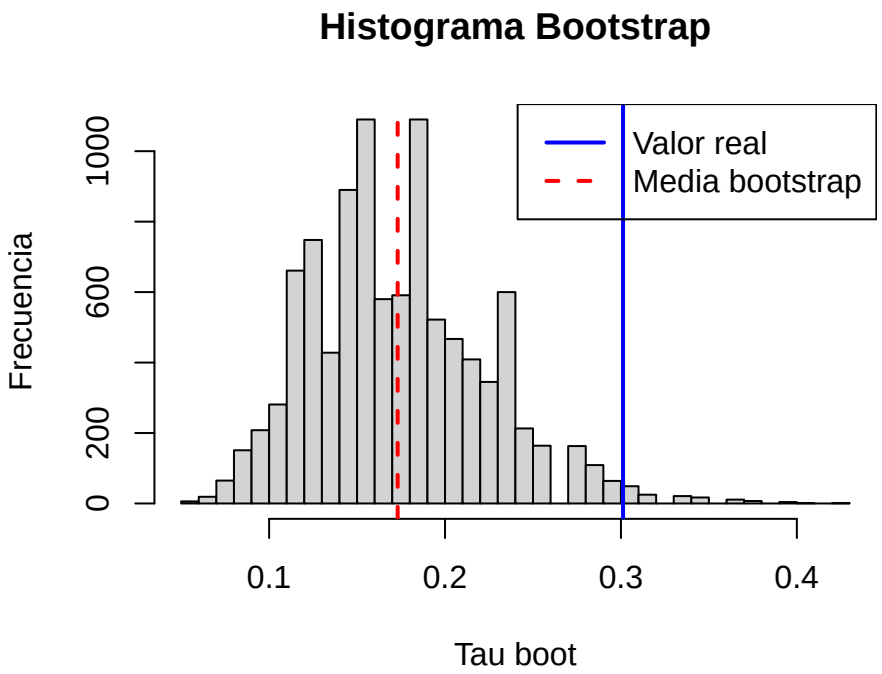


A continuación, se presenta la aplicación del segundo enfoque, el método Bootstrap no paramétrico, a la muestra de datos proporcionada: (0, 0, 2, 0, 2, 1, 2, 2, 4, 3, 0, 2, 2, 2, 6, 4, 1, 1, 2, 2, 0, 1, 2, 1, 2). Utilizando $B = 10,000$ remuestras extraídas de la misma distribución, el propósito es estimar el parámetro *hattau* y construir su correspondiente intervalo de confianza del 95%. Los resultados obtenidos son:

Categoria	Medida	Valor
Parámetro Real	Valor real	0.301194211912202
Estimador en la Muestra	Muestra	0.16593356876395
Estimaciones Bootstrap	Media bootstrap	0.173065220121726
	Varianza bootstrap	0.00243454125152528
Intervalo Normal	Límite inferior	0.0620951960005982
	Límite superior	0.255508638811748
Intervalo Percentil	Límite inferior	0.0936982579048444
	Límite superior	0.282103337501477

Table 2: Resultados del Bootstrap

Es evidente que las estimaciones se encuentran muy lejos del valor real que intentamos estimar. Además, los intervalos de confianza, calculados mediante el método de percentiles y bajo el supuesto de una distribución normal, tampoco consiguieron contener dicho valor.



Dado que los datos no parecen seguir una distribución normal, no sería aconsejable utilizar intervalos basados en la distribución t-Student. Por consiguiente, por el momento, no consideraremos al método boot ni a los intervalos que esta nos da como una estimación adecuada.

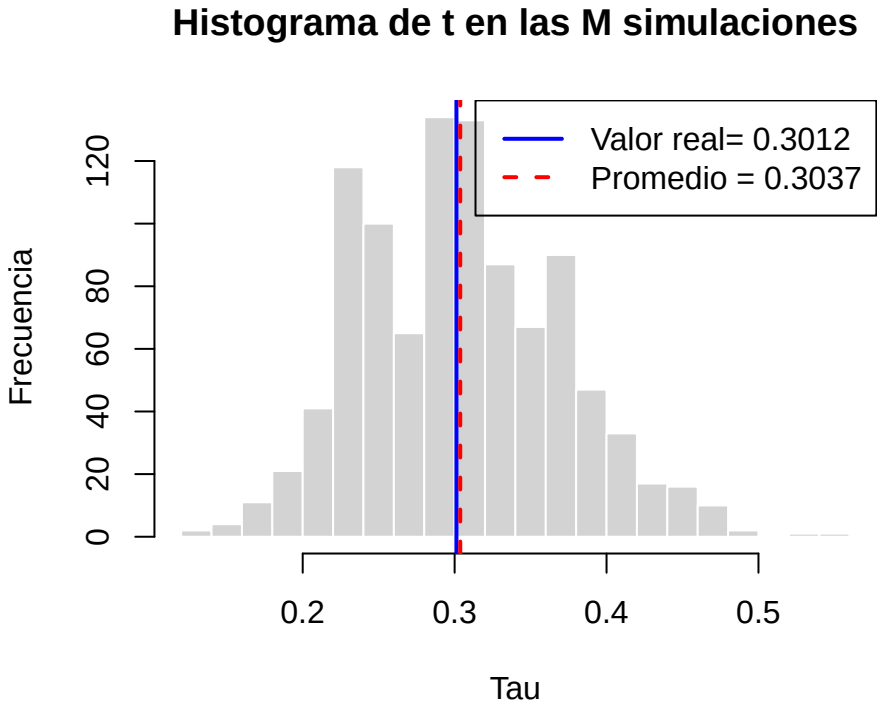
Notemos que el método bootstrap depende tanto del número de remuestreos utilizados como de la muestra original sobre la cual se aplica. Por esta razón, consideramos nuevamente el método bootstrap, pero ahora generamos una muestra simulada de tamaño $n = 25$ proveniente de la distribución de interés. Para cada muestra realizamos $B = 10,000$ remuestreos bootstrap no paramétricos y calculamos el estimador correspondiente. Con el fin de evaluar el comportamiento del estimador y del intervalo de confianza, repetimos todo este procedimiento mediante una simulación Monte Carlo con $M = 1,000$ replicaciones independientes.

Table 3: Resumen general

Medida	Valor
Valor real	0.301194
Estimación promediô	| 0.30370
Cobertura IC Normal	0.925000

Tras la aplicación del método bootstrap con $M = 1,000$ simulaciones, se constata que el valor resultante converge de manera significativa al valor teórico esperado. Adicionalmente, la simulación arrojó una cobertura del 92.5% para los intervalos normales, lo que implica que dichos intervalos abarcaron el valor verdadero en el 92.5% de los casos. Por lo tanto, consideramos que en este caso el resultado puede compararse satisfactoriamente con el método de Monte Carlo.

Ahora de manera gráfica



Además, gráficamente se puede apreciar aún más esta cercanía. No obstante, dado que los datos no presentan un comportamiento normal, no se podrán obtener los intervalos de confianza mediante la distribución t de Student. Sin embargo, al observar los promedios de los intervalos de confianza basados en percentiles y en la distribución normal, se nota que estos son relativamente estrechos y, adicionalmente, incluyen el valor teórico que se desea estimar.

Table 4: Intervalos de confianza

Metodo	Inferior	Superior
Normal	0.175563	0.431845
Percentil	0.187552	0.442002

Conclusión

Con base en las observaciones realizadas, se puede concluir que el método de simulación de Monte Carlo es la estrategia más adecuada para estimar el valor buscado. Si bien el valor obtenido mediante el método bootstrap combinado con simulación fue muy cercano, el método de Monte Carlo aplicado a la muestra original arrojó un valor significativamente más alejado. Esto último se debe a que su precisión está condicionada por la muestra inicial y el proceso de remuestreo.

No obstante, en un contexto real, resulta complejo determinar a priori la distribución de la cual proviene la muestra. Por consiguiente, aunque el método de Monte Carlo con la distribución conocida sea el más idóneo en teoría, su aplicabilidad práctica es limitada. En este sentido, la tercera opción (simulación con bootstrap) se configura como la mejor alternativa, puesto que incluso se lograron niveles de aceptación satisfactorios en los intervalos de confianza.

Resumen Ejecutivo 2

Consideramos la base de datos fat del paquete faraway,donde el objetivo del estudio es usar las variables clínicas observadas en los pacientes para estudiar cuáles de éstas son los factores que ayudan a modelar mejor el promedio del porcentaje de grasa corporal en los hombres (variable brozek).

Modelos de efectos principales con distribución Gaussiana y liga identidad

Con el metodo del mejor subconjunto:

Con este método podemos observar que las variables que seleccionó el algoritmo fueron age, height, neck, chest, abdom, forearm y wrist, las cuales son las que mejor nos ayudan a modelar a nuestra variable de porcentaje de grasa corporal, con un AIC de 1390.57

Ahora usaremos un método step:

Con este método podemos ver que las variables que se seleccionaron fue age, adipos, neck, chest, abdom, hip, forearm y wrist, con un AIC de 1391.47

Para el método Lasso:

Con este método vemos que las variables que nos deja el algoritmo son age, height, neck, abdom y wrist, con un AIC de 1391.76

Método	AIC
Mejor subconjunto	1390.577
Stepwise	1391.475
Lasso	1391.761

Modelos con interacciones con distribución Gaussiana y liga identidad

Con el metodo Stepwise tenemos:

Con este método podemos ver que tenemos a age, height, chest, abdom, thigh, ankle, biceps, wrist y 5 interacciones, esto nos indica que hay relaciones entre las variables que al estar multiplicandose tienen un efecto mayor en el porcentaje de grasa corporal.

El AIC para este modelo es 1379.14

Para el método Lasso:

Con este método obtuvimos que las variables que entran son age, weight, hip, thigh, knee, biceps, forearm, wrist y 28 variables de interacciones, donde podemos destacar que aunque adipos no entró como efecto principal si tenemos que su interacción con age, weight, height y ankle entran en el modelo.

El AIC de este modelo es 1387.97

Método	AIC
Stepwise	1379.145
Lasso	1387.978

Modelos de efectos principales, con variables cuadráticas con distribución Gamma y liga identidad

Para el método Stepwise:

Con este método tenemos que las variables que entran en el modelo son age, weight, neck, abdom, hip, thigh, knee, biceps, forearm, wrist, así como las variables cuadráticas de biceps, forearm, neck, abdom y weight.

Con un AIC de 1437.

Para el método Lasso:

Con el método Lasso tenemos que las variables que entran en el modelo son age, weight, height, neck, chest, thigh, knee, biceps, forearm, wrist, así como las variables caudráticas de age, weight, adipos, neck, abdom, hip, thigh, ankle, biceps, forearm.

Con un AIC de 1444

Método	AIC
Stepwise	1436.998
Lasso	1444.038

Modelos de efectos principales, interacciones, variables cuadráticas con distribución Gamma y liga identidad

Para el método Stepwise tenemos:

En este modelo las variables que entran en el modelo son age, weight, height, neck, chest, abdom, hip, thigh, knee, biceps, forearm, wrist, la vaiable cuadrática de neck, así como 6 variables de interacción.

Con un AIC de 1424

Para el método Lasso:

Con este método tenemos que entran las variables weight, height, neck, chest, abdom, thigh, knee, biceps, forearm, wrist, así como 9 variables cuadráticas y 22 interacciones.

Con un AIC de 1448

Método	AIC
Stepwise	1424.458
Lasso	1448.248

Mejor modelo:

Tenemos que la variable wrist entró en todos los modelos que fueron seleccionados con estos algoritmos, y las variables que más se repiten son age, abdom, forearm, neck, biceps, chest, height, thigh, knee, weight y hip.

Basándonos en el criterio del AIC con el que escogimos todos nuestros modelos, tenemos que el modelo con el AIC más pequeño fue el modelo donde utilizamos el método Stepwise con direccción "both" donde tenemos interacciones, con función Gaussiana y liga identidad. El modelo incluye las variables age, height, chest, abdom, thigh, ankle, biceps, wrist, con la interacciones entre age:wrist, thigh:biceps, ankle:wrist, height:ankle y biceps:wrist. Vemos que para este caso si es necesario incluir interacciones en el modelo pues esto indica que nos ayudan a modelar mejor el porcentaje de grasa en el cuerpo.

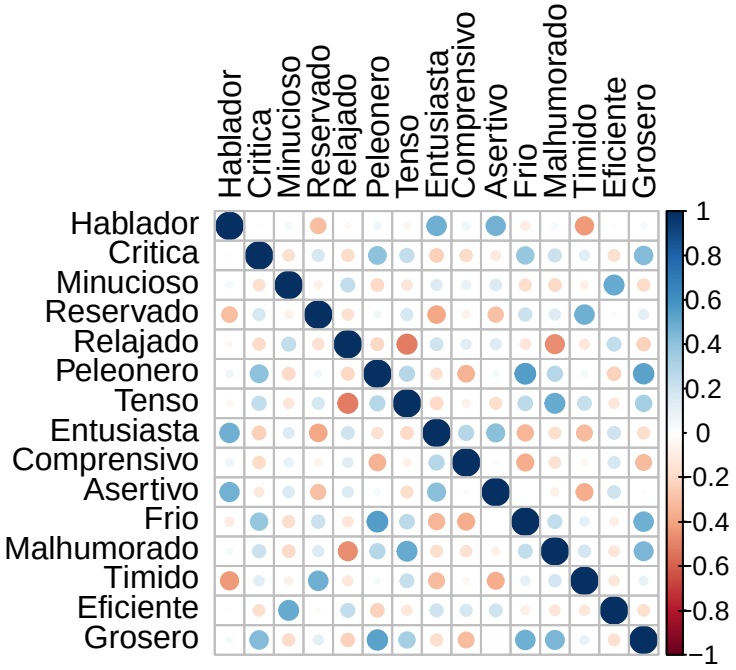
Podemos decir el que el efecto de la interacción de wrist con age, ankle y height influyen directamente al modelo, estos teniando un mayor afecto cuando interactuan, que si solo entran como efecto principal.

Resumen Ejecutivo 3

La base de datos "Dat3T.csv" contiene las respuestas de 228 estudiantes universitarios en Estados Unidos, quienes contestaron un cuestionario sobre distintos rasgos de personalidad. El objetivo general del análisis es encontrar uno o varios indicadores que resuman la información principal del conjunto de variables, usando dos métodos: Análisis de Componentes Principales (ACP) y Análisis Factorial Exploratorio (AFE).

Las variables seleccionadas corresponden a 15 afirmaciones del cuestionario, que representan diferentes rasgos de personalidad tales como ser Hablador (V1), Critica (V2), Minucioso (V3), Reservado (V6), Relajado (V9), Peleonero (V12), Tenso (V14), Entusiasta (V16), Comprensivo (V17), Asertivo (V26), Frío (V27), Malhumorado(V29), Timido (V31), Eficiente(V33) y Grosero (V37). Todas ellas fueron contestadas con la misma escala del 1 al 5, donde 1 significa total desacuerdo y 5 total acuerdo. Esta escala es de tipo ordinal, lo que implica que las respuestas tienen un orden, aunque la distancia entre categorías no necesariamente es igual. Este detalle será importante al momento de elegir algunos métodos de análisis.

Antes de aplicar ACP o AFE, se revisó la matriz de correlaciones para observar qué tan relacionadas están las variables entre sí. Esto permite identificar patrones y justificar si es adecuado utilizar estos métodos de reducción de dimensiones.



La matriz muestra relaciones esperadas entre varios rasgos. Por ejemplo, Hablador se relaciona positivamente con Entusiasta, mientras que Minucioso se relaciona de manera importante con Eficiente. También se observan relaciones negativas claras, como entre ser Reservado y ser Hablador, o entre Relajado y rasgos emocionales como Tenso o Malhumorado. Estas asociaciones justifican el uso de técnicas como el ACP y el AFE, ya que permiten identificar grupos de variables que se mueven juntas y que podrían representar dimensiones más amplias de personalidad.

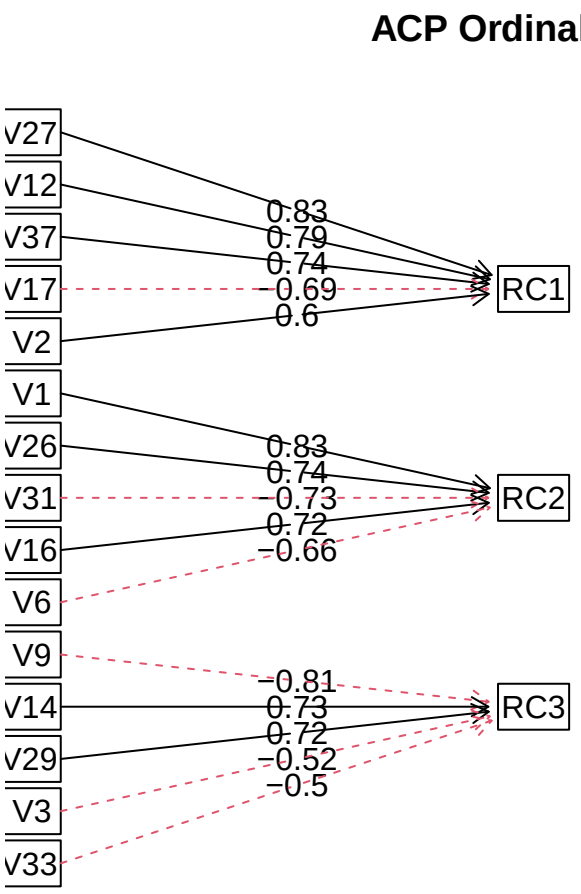
Durante el análisis, se probaron diferentes configuraciones:

1. Trabajar con los datos originales, estandarizados y transformados.
2. Probar varias rotaciones para facilitar la interpretación.
3. Considerar las variables como ordinales mediante el uso de correlaciones policóricas.

4. Ajustar modelos con tres y con cuatro componentes o factores para evaluar cuál estructura era más clara y útil.

Las decisiones finales se tomaron priorizando la claridad en la interpretación, la fuerza de las relaciones entre variables y la carga o correlaciones con cada componente.

Análisis de tres componentes principales



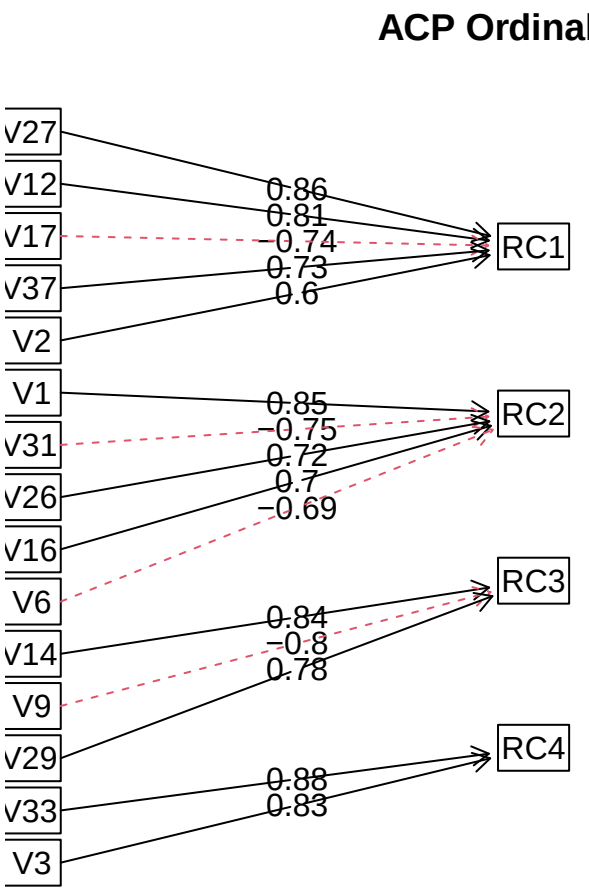
El análisis inicial con **tres componentes rotados con Varimax** considerando datos **ordinales** permitió identificar patrones amplios en los rasgos evaluados (ver chunk best_3 para mayor detalle):

RC1 – Frialdad o dureza interpersonal Este componente reúne rasgos que reflejan una forma de relacionarse de manera distante o incluso conflictiva: ser frío, crítico, grosero o peleonero. En oposición, el rasgo Comprensivo aparece con carga negativa. En conjunto, representa un eje que va desde personas más empáticas hasta personas más duras o agresivas en el trato.

RC2 – Estilo de expresión social Este componente distingue a personas más activas y expresivas (Hablador, Asertivo, Entusiasta) de quienes tienden a retraerse (Tímido, Reservado). Es un continuo entre extraversión y conducta social inhibida.

RC3 – Mezcla entre tensión emocional y autoexigencia Aquí se combinan rasgos como Tenso o Malhumorado con otros más relacionados al orden y disciplina, como Minucioso y Eficiente. Esto sugiere un patrón donde la autoexigencia puede venir acompañada de cierta tensión emocional. Sin embargo, esta mezcla indica que el componente junta dos áreas distintas que podría ser mejor separar.

Modelo de cuatro componentes principales



Tras evaluar varias configuraciones, el modelo de **cuatro componentes principales con correlaciones policóricas y rotación Cluster** resultó ser la estructura más clara, coherente y conceptualmente diferenciada. Esta solución permitió desagrupar dominios que en el modelo de tres componentes aparecían mezclados, generando factores más puros y fáciles de interpretar.

Cada componente capturó una faceta distinta de los rasgos evaluados, y juntos ofrecieron una representación más precisa de la organización de la personalidad en la muestra.

1. RC1 – Hostilidad interpersonal vs. calidez y comprensión

El primer componente representa un eje muy consistente de conductas relacionadas con la frialdad emocional y la agresividad interpersonal. Rasgos como Frío, Grosero, Peleonero y Crítico muestran cargas positivas elevadas, indicando que este factor agrupa comportamientos rudos, distantes y potencialmente conflictivos. En contraste, Comprensivo carga de manera negativa, ubicándose en el extremo opuesto del componente.

La nitidez de este factor sugiere que los individuos tienden a ubicarse de forma consistente en uno de estos polos, sin mezclas problemáticas con otros dominios.

2. RC2 – Extraversión vs. inhibición o retraimiento social

El segundo componente captura de manera muy limpia los rasgos relacionados con el estilo de expresión social. Variables como Hablador, Entusiasta y Asertivo presentan altas cargas positivas, conformando el polo más activo y expresivo del factor. Por otro lado, Tímido y Reservado cargan negativamente, reflejando conductas de retraimiento, menor participación social y tendencia a evitar situaciones de interacción.

3. RC3 – Tensión emocional y malestar afectivo

El tercer componente reúne únicamente rasgos emocionales, lo que lo convierte en un factor mucho más coherente que su equivalente en el modelo de tres componentes. Rasgos como Tenso y Malhumorado presentan las cargas positivas más altas, mientras que Relajado carga negativamente con gran magnitud, marcando una relación muy clara.

A diferencia del modelo de tres componentes, aquí no se mezclan rasgos laborales como Minucioso o Eficiente, lo que fortalece la interpretación y la calidad estructural del componente.

4. RC4 – Orden y responsabilidad.

El cuarto componente agrupa de manera muy definida los rasgos Minucioso y Eficiente, que presentan cargas elevadas y exclusivas en este factor. Esto lo convierte en una dimensión clara de:

Organización, responsabilidad, cuidado por los detalles y eficiencia en el trabajo.

Este componente coincide con patrones habitualmente asociados al rasgo de responsabilidad. Su separación completa de los rasgos emocionales (algo que no ocurría en el modelo de tres componentes) indica que la estructura de cuatro factores captura mejor la independencia que el de tres factores.

Conclusión interpretativa del modelo de cuatro componentes

El modelo de cuatro componentes presenta una estructura psicológicamente más limpia y conceptualmente más diferenciada que el modelo de tres factores. La separación entre tensión emocional y orden/eficiencia, que en el modelo anterior aparecían combinados, constituye una mejora importante en claridad. Además, las dimensiones obtenidas son coherentes con dominios clásicos de personalidad: hostilidad/calidez, extraversión, afectividad negativa, y responsabilidad, lo que fortalece la plausibilidad del modelo como representación válida de los datos recolectados.

Finalmente, el uso de correlaciones policóricas (coherente con la naturaleza ordinal de las respuestas) produjo un incremento pequeño en algunas de las correlaciones entre los ítems, lo que permitió obtener factores ligeramente más definidos y con una estructura más coherente.

Por otro lado, aunque también se exploró un análisis factorial exploratorio (AFE) utilizando distintos métodos y criterios, este enfoque no resultó tan eficiente para separar claramente los dominios conceptuales. Si bien varios modelos factoriales ofrecieron soluciones similares en términos generales, ninguno logró superar la correlación y coherencia interpretativa alcanzada por el modelo de componentes principales.

Resumen Ejecutivo 4

El presente análisis utiliza la información de la encuesta realizada por la aerolínea Oddjob Airways con el objetivo de evaluar las expectativas de sus clientes respecto a diversos aspectos del servicio ofrecido. El propósito principal es identificar, mediante técnicas de agrupamiento, la existencia de segmentos diferenciados de clientes. Estos grupos pueden servir como base para futuras estrategias comerciales y campañas de marketing más focalizadas.

De esta manera, todas las respuestas se encuentran en una escala de 1 a 100, donde 100 representa que el cliente considera un aspecto altamente relevante y 1 indica que no lo es. Además, el análisis se realizó con base en 13 preguntas específicas de la encuesta, por lo que de los 1,065 encuestados, solo se consideraron 934 respuestas, ya que era requisito que cada participante respondiera todas las preguntas.

Comenzando con el análisis, el primer método de agrupamiento empleado es k-means, un método de aprendizaje no supervisado que divide un conjunto de datos en k grupos o clústeres. Al aplicar este algoritmo a nuestros datos originales y estandarizados (restando la media y dividiendo entre la desviación estándar), se obtuvieron distintos agrupamientos, estadísticas y gráficas, los cuales pueden consultarse en los chunks *"kmeansori"* y *"kmeanstand"*.

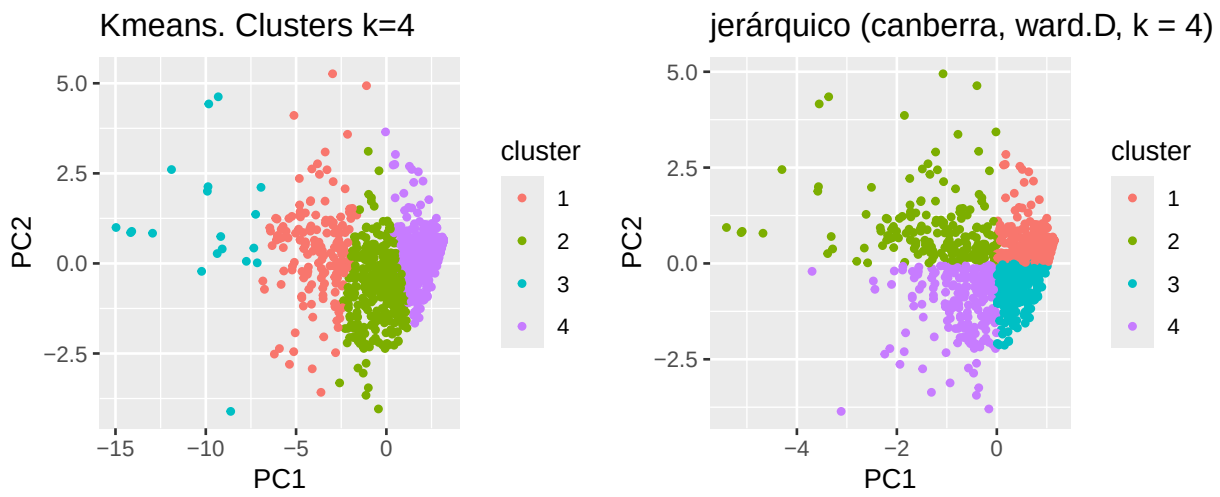
Con ello, fue posible observar cómo los clientes se agrupan según patrones similares en sus respuestas. No obstante, es necesario realizar un análisis más profundo para identificar los conglomerados que resultan más adecuados y su interpretación. Por esta razón, se llevó a cabo un análisis mediante conglomerados jerárquicos aglomerativos, empleando distintas distancias (euclidean, maximum, manhattan y canberra), disimilaridades (ward.D, ward.D2, complete y average) y valores de k (2, 3, 4 y 5). Los resultados correspondientes se encuentran en el chunk *"jerardatos"*.

Mediante el método de conglomerados jerárquicos se obtuvieron numerosos resultados, por lo que, para optimizar el análisis y decidir cuántos y cuáles clústeres emplear, se recurrió al método de componentes principales. De este procedimiento se obtuvo lo siguiente:

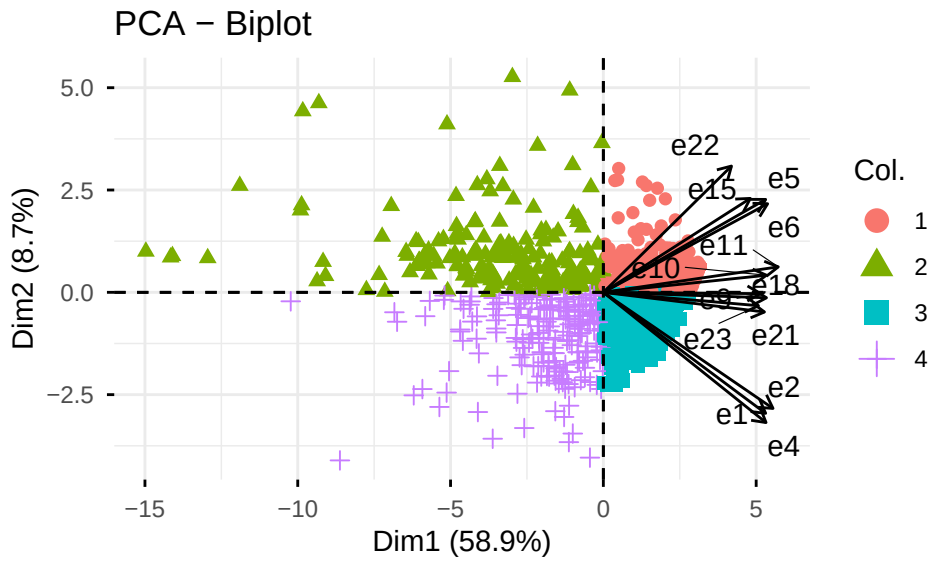
Componente	Varianza	Varianza Acumulada
PC1	0.5892	0.5892
PC2	0.0871	0.6763
PC3	0.0531	0.7294
PC4	0.0456	0.7750
PC5	0.0412	0.8162

Esto indica que con cinco componentes principales se supera el 80% de la varianza explicada, lo cual es satisfactorio. Sin embargo, al analizar los biplots con cinco componentes, la interpretación no resulta del todo clara. En cambio, utilizando solo cuatro componentes, la segmentación es más adecuada y mantiene un nivel de explicación alto, equivalente al 78% de la varianza.

En este sentido, a continuación se presentan dos gráficas de conglomerados con $k = 4$ sobre los datos estandarizados: una obtenida mediante el método k-means y otra mediante conglomerados jerárquicos utilizando distancia Canberra y método de enlace ward.D.



Por el lado izquierdo observamos que los clústeres solo se segmentan con respecto al Componente Principal 1, ya que las particiones parecen ser líneas verticales que se desplazan sobre el eje de Comp1. Por su parte, la segunda gráfica resulta más compleja, pues los clústeres parecen segmentarse en un plano cartesiano, dependiendo tanto del Componente Principal 1 como del 2. Con ello, se decidió trabajar con los conglomerados obtenidos mediante el método jerárquico con distancia Canberra y enlace ward.D. A continuación se muestran los clústeres respecto a las variables.

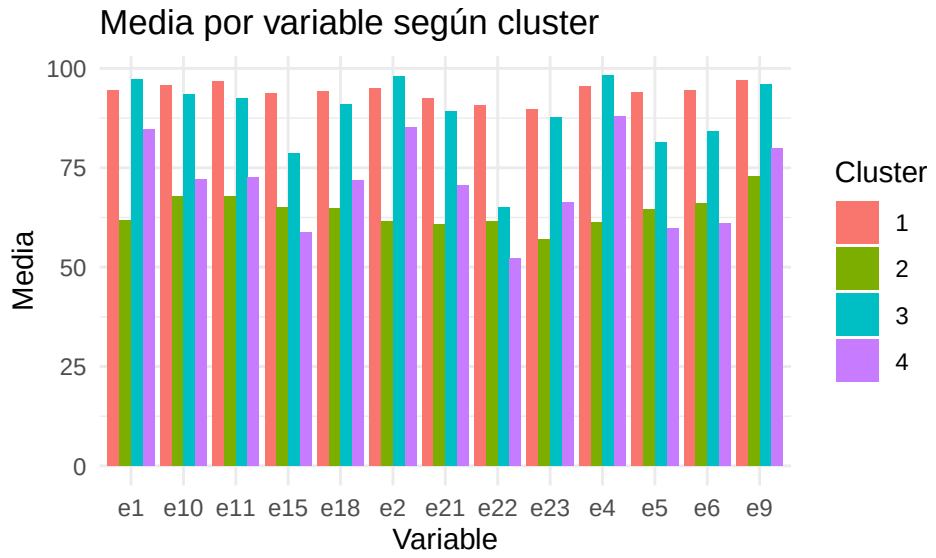


Podemos ver que, en el clúster 1, se encuentran las personas cuyas respuestas presentan valores elevados en las variables que apuntan hacia arriba y a la derecha (e15, e22, e5 y e6). Estas preguntas están relacionadas en saber si los clientes consideran importante que Oddjob Airways ofrezca entretenimiento, instalaciones adecuadas, servicio e información, alimentos y bebidas de alta calidad, así como que la experiencia de viaje sea agradable.

Por otro lado, en el clúster 3 se ubican los clientes con mayores valores en las preguntas e2, e1 y e4, centradas en determinar si el vuelo se realiza a tiempo y según lo programado. Respecto al clúster 2, estas personas se sitúan justo en el lado contrario del clúster 3, lo que indica que no otorgan importancia a que los vuelos se

realicen puntualmente. Un razonamiento similar puede hacerse para el clúster 4, cuyos viajeros no comparten las mismas expectativas positivas que presentan las personas en el clúster 1.

Para corroborar lo anterior, se presenta la siguiente gráfica de barras que muestra la media de las respuestas originales de cada clúster con respecto a las preguntas sobre las expectativas hacia la compañía.



Esto confirma lo mencionado anteriormente: las personas de los clústeres 1 y 3 presentan expectativas más altas respecto a las características de la compañía que los sujetos de los clústeres 2 y 4. Analizando con mayor detalle, se observa que los integrantes del clúster 1 tienen las medias más altas en todas las preguntas, excepto en las variables 1, 2 y 4, que están relacionadas con la puntualidad del vuelo y en las que el clúster 3 obtiene valores superiores.

Por su parte, los sujetos del clúster 2 muestran las medias más bajas en la mayoría de los casos, salvo en las preguntas 5, 6, 22 y 15, donde superan al grupo 4. Dichas preguntas se refieren principalmente a las amenidades del vuelo y las condiciones del avión.

Además, es importante también conocer cuántas personas hay en cada clúster, como se muestra a continuación:

Cluster	**Número de personas**
1	341
2	180
3	215
4	198

Puede observarse que el clúster 1 es el más numeroso, mientras que el clúster 2 es el que presenta el menor número de individuos. Esto indica que existe una mayor proporción de clientes que valoran que las condiciones del vuelo sean adecuadas.

Ahora bien, podemos describir cada clúster de la siguiente manera:

- En el clúster 1 se encuentran las personas que consideran todos los aspectos importantes, con mayor interés en las amenidades durante el vuelo.
- En el clúster 2 están quienes no valoran en general los atributos evaluados, pero especialmente muestran desinterés por la puntualidad.

- En el clúster 3 se ubican los clientes que consideran todos los aspectos relevantes, pero otorgan mayor peso a la puntualidad de los vuelos.
- En el clúster 4 se encuentran las personas que no consideran los aspectos evaluados como esenciales, pero especialmente muestran poco interés en las amenidades del avión.

En conclusión, se recomienda que la publicidad de Oddjob Airways se dirija a individuos con perfiles similares a los identificados en los clústeres 1 y 3, es decir, personas que valoran la calidad integral del servicio y, en particular, la puntualidad o las amenidades a bordo. Este segmento representa el mercado con mayor potencial para atraer nuevos clientes que buscan una mejor experiencia de vuelo y que podrían mostrar mayor lealtad si la aerolínea cumple con sus expectativas.